République du Sénégal
Un peuple - Un but - Une foi

Ministère de l'Economie, du Plan et de la Coopération (MEPC)

Agence nationale de la Statistique et de la Démographie (ANSD)

ANSD
Agence Nationale de
la Statistique et de la Démographie

Ecole nationale de la Statistique et de l'Analyse économique Pierre Ndiaye (ENSAE)

ensae

Direction de la Méthodologie, de la Coordination Statistique et de l'Innovation (DMCI)

Rapport de stage

THÈME

MISE EN PLACE D'UNE APPLICATION WEB POUR L'AUTOMATISATION DES PROCEDURES D'ECHANTILLONNAGE

Rédigé par :

Faïçal Cheick Hamed OUEDRAOGO

Elève Analyste Statisticien

Supervisé par :

M. Mamadou MBODJ

Scientifique des données à la DMCI

M. Assana-Richard AYIZOU

Ingérieur statisticien économiste (ISE)

Décembre 2024

Décharge

L'Ecole nationale de la Statistique et de l'Analyse économique Pierre NDIAYE (ENSAE) et la Direction de la Méthodologie, de la Coordination statistique et de l'Innovation (DMCI) n'entendent donner aucune approbation ni improbation aux opinions émises dans ce rapport. Ces opinions doivent être considérées comme propres à l'auteur.

Remerciements

Au terme de notre stage, nous dédions ces quelques lignes pour adresser nos chaleureux remerciements à tous ceux qui ont participé à la bonne rédaction de ce rapport. Je veux mentionner en premier Dr. Abdou DIOUF Directeur Général de l'ANSD, Dr Momath CISSE Directeur de la DMCI et actuel Directeur Général Adjoint de l'ANSD pour avoir accepter de me recevoir au sein de la direction. Je remercie également M. Fodé DIEME Responsable de la Division de la Méthodologie et de l'Innovation ainsi que M. Moussa DIALLO Responsable du Bureau de Recherche et Innovation, bureau au sein duquel j'ai effectué mon stage.
Mes remerciements vont également à l'endroit de mes encadreurs M. Mamadou MBODJ, Data scientist et M. Assana-Richard AYIZOU, Ingénieur statisticien économiste, à la DMCI qui m'ont permis d'effectuer mon stage dans de bonnes conditions et de m'avoir suivi régulièrement durant ces 2 mois. Mes remerciements vont également à l'endroit de Mme DIOUF, M. Moustapha MBENGUE, M.Ousseynou MBAYE, M. Cheikh GUEYE,M. Mamadou GUEYE et à l'ensemble du personnel de la DMCI pour leur accueil, leur partage et leur ouverture d'esprit.
Je remercie l'ensemble du corps administratif et professoral de l'ENSAE en l'occurrence M. Idrissa DIAGNE, Directeur de l'ENSAE, Dr Alassane AW, Responsable de la filière des Analystes Statisticiens (AS), M. Mamadou BALDE, Responsable de la filière des Ingénieurs Statisticiens Économistes (ISE) et Dr. Souleymane FOFANA, Chef de l'Unité de recherche de l'ENSAE.
Je remercie tout particulièrement mes camarades, la promotion AS 2022-2025 pour l'esprit de solidarité et de fraternité qui a toujours régné entre nous. Qu'il me soit permis, enfin, de remercier toutes les autres personnes qui n'ont pas pu être mentionnées mais qui, de près ou de loin, se sont impliquées d'une manière ou d'une autre dans l'aboutissement de ce travail.

Avant-Propos

Située au Sénégal et précisément à Dakar, l'École nationale de la Statistique et de l'Analyse Économique Pierre Ndiaye (ENSAE) est un établissement d'enseignement supérieur rattaché à l'Agence nationale de la Statistique et de la Démographie (ANSD). Elle est en relation avec trois autres écoles du même statut à savoir l'École nationale Supérieure de la Statistique et de l'Économie appliquée (ENSEA) d'Abidjan l'Institut Sous régional de la Statistique et de l'Économie Appliquée (ISSEA) de Yaoundé et l'Ecole nationale d'Economie appliquée et de Management (ENEAM) de Cotonou avec lesquelles elle forme le Réseau des Ecoles de Statistiques Africaines (RESA).

L'offre de formation initiale de l'ENSAE comprend la formation des Ingénieurs statisticiens économistes (ISE) en cycles court et long et des Analystes statisticiens (AS). L'admission s'y fait par voie de concours. Elle dispose également des Masters spécialisés tels que le master « Aide à la Décision et Evaluation des Politiques Publiques » (ADEPP) et le Master Agricole.

La formation du cycle AS dure 3 ans avec un stage d'immersion en fin de 2è année. L'objectif de ce stage est de permettre aux élèves analystes de mettre en pratique les connaissances théoriques acquises au cours des 2 premières années d'enseignement dans un institut national ou régional de statistique et de produire un rapport de stage qui sera soutenu devant un jury au cours de la 3è année. C'est dans ce cadre que nous avons effectué un stage de deux mois à la Direction de la Méthodologie, de la Coordination statistique et de l'Innovation (DMCI) à l'ANSD. Au cours de ce stage, nous avons travaillé à la **"Mise en place d'une application pour l'automatisation des procédures d'échantillonnage"**. Cette application est développée en utilisant le framework Streamlit de Python et permet aux utilisateurs de définir les méthodes d'échantillonnage, de tirer l'échantillon à partir d'une base de sondage et de télécharger une note méthodologique détaillant les méthodes utilisées.

Sommaire

Remerciements ii

Avant-propos iii

Sommaire iv

Liste des figures v

Liste des tableaux vi

Sigles et Acronymes vii

Résumé viii

Abstract ix

Introduction générale 1

1 Présentation de la structure d'accueil 2

2 Définitions et méthodologie des sondages 7

3 Présentation de l'application 20

4 Cas d'utilisation de SamPower 26

Conclusion et recommandations 29

Bibliographie xiii

Annexe xiv

Liste des Figures

2.1 *Illustration du sondage aléatoire simple* 13
2.2 *Illustration du sondage stratifié* 18

3.1 *Page d'accueil de SamPower* 22
3.2 *Sondage aléatoire simple* 23
3.3 *Sondage stratifié* 24

4.1 *Organigramme de l'ANSD* xiv

Liste des tableaux

4.1 Description des variables 26

Table des sigles et abréviations

ANSD	Agence nationale de la Statistique et de la Démographie
AS	Analyste Statisticien
BRI	Bureau de la Recherche et de l'Innovation
DMCI	Direction de la Méthodologie, de la Coordination statistique et de l'Innovation
DMCP	Direction de la Méthodologie, de la Coordination statistique et des Partenariat
DMI	Division de la Méhodologie et de l'Innovation
ENSAE	Ecole nationale de la Statistique et de l'Analyse économique Pierre NDIAYE
PSD	Plans Stratégiques de Développement
SamPower	Sampling Power
SNDS	Stratégies Nationales de Développement de la Statistique
SSN	Système statistique national

Résumé

Définir une méthode de sondage adéquate constitue une étape fondamentale pour la mise en oeuvre d'une enquête statistique. En vue d'accompagner les structures statistiques dans la mise en oeuvre des enquêtes officielles, le Bureau de la Recherche et de l'Innovation de l'ANSD a entamé un projet de mise en place d'une plateforme innovante pour permettre aux praticiens de concevoir plus aisement des plans de sondage suivant les normes statistiques. Dans ce cadre, le travail réalisé dans ce document vise à présenter une application web développée avec le framework Streamlit de Python en intégrant des méthodes statistiques de tirage d'échantillon telles que le tirage aléatoire simple et le tirage stratifié. Cette plateforme, dénommée SamPower (Sampling Power), est flexible et permet de prendre en compte des paramètres spécifiques dans le but d'améliorer la représentativité de l'échantillon tiré. Elle met à la disposition des utilisateurs un rapport détaillée des résultats obtenus et une base de données des personnes sélectionnées pour l'enquête. Un cas pratique a été réalisé sur la base de données EHCVM 2021 pour montrer l'efficacité de SamPower. Les résultats obtenus montrent une bonne représentativité des échantillons par rapport à la population.

Mots clé : Echantillonnage, sondage aléatoire simple, sondage stratifié, Streamlit

Abstract

Defining an appropriate sampling method is a fundamental step in conducting a statistical survey. To support statistical organizations in implementing official surveys, the Bureau of Research and Innovation of ANSD initiated a project to develop an innovative platform that enables practitioners to design sampling plans more easily, in line with statistical standards. In this context, the work presented in this document introduces a web application developed using Python's Streamlit framework, incorporating statistical sampling methods such as simple random sampling and stratified sampling. This platform, named SamPower (Sampling Power), is flexible and allows the inclusion of specific parameters to improve the representativeness of the selected sample. It provides users with a detailed report of the obtained results and a database of individuals selected for the survey. A practical case study was conducted using the EHCVM 2021 dataset to demonstrate SamPower's effectiveness. The results obtained show good representativeness of the samples compared to the population, validated through comparative analyses and statistical tests, notably the Chi-square test.

Keywords : Sampling, simple random sampling, stratified sampling, Streamlit.

Introduction

Dans un monde où les données occupent une place centrale dans la prise de décision, les enquêtes par sondage restent des outils fondamentaux pour collecter des informations fiables et représentatives. Cependant, les méthodes traditionnelles d'échantillonnage peuvent s'avérer longues, sujettes à des erreurs humaines et difficiles à reproduire. Ces défis sont particulièrement accentués dans le contexte de la coordination des structures produisant des statistiques officielles qui,généralement dans un environnement de ressources limitées, doivent réaliser des études dans des délais limités.

L'automatisation des procédures d'échantillonnage présentent un intérêt fondamental pour rationaliser le processus et réduire les délais. Dans cette dynamique, le Bureau de la Recherche et de l'Innovation au sein de la DMCI a inité un projet visant à mettre en place une plateforme interactive pour la conception de plan de sondage. Ce projet répond à des enjeux opérationnels majeurs tels que la standardisation des méthodes, l'amélioration de la transparence et l'optimisation des ressources.

Dans le cadre de ce stage, nous avons développé une application innovante permettant d'automatiser la sélection des échantillons selon différentes méthodologies et donc de répondre à l'objectif visé dans le projet. Cette application, SamPower, intègre des approches statistiques robustes tout en offrant une interface conviviale pour les utilisateurs non spécialisés. L'objectif est de démontrer que l'automatisation peut non seulement simplifier les opérations, mais aussi améliorer la qualité des résultats obtenus.

Pour atteindre cet objectif, notre étude sera structurée en quatre chapitres. Le premier chapitre présente la structure d'accueil et résume les activités menées pendant le stage. Le deuxième chapitre se penchera sur le cadre théorique de notre étude et examinera les aspects méthodologiques des sondages. Le troisième chapitre comportera la présentation de l'application et le dernier chapitre portera sur une évaluation de l'application à travers des études de cas pratiques. Nous conclurons notre travail par la formulation de recommandations.

Chapitre

1 Présentation de la structure d'accueil

Dans cette partie, nous allons présenter brièvement la structure ayant servi de cadre de stage c'est-à-dire l'Agence Nationale de la Statistique et de la Démographie (ANSD). Pour ce faire, nous ferons ressortir ses missions et attributs après quoi nous présenterons les différentes directions qui la composent.

1.1 Présentation de l'ANSD

1.1.1 Historique et missions de l'ANSD

Créée en 2004 par la loi N° 2004-21 du 12 juillet 2004 portant organisation des activités statistiques, l'ANSD est une structure administrative dotée de la personnalité juridique et d'une autonomie de gestion placée sous tutelle du ministre chargé de la statistique et sous gouvernance d'un Conseil de Surveillance. Elle est dirigée par un Conseil de Surveillance de représentants de la Primature, du MEF, de la Banque Centrale, des organisations patronales, des centrales syndicales des travailleurs et des centres de recherche universitaire. Elle a comme organe de direction exécutive la Direction générale dont le Directeur général et le Directeur général adjoint sont, tous deux, nommés par décret. Son rôle est d'assurer la cohésion technique des différentes activités du Système Statistique National (SSN) et de veiller, par la même, à la production et la diffusion des données statistiques. Ces dernières serviront d'appui aux Gouvernement, administrations publiques, de même

que le secteur privé et les partenaires au développement. La mission de l'ANSD s'articule autour des points suivants :

- Veiller à l'élaboration et à la mise en œuvre des programmes pluriannuels et annuels de statistique
- Assurer la mise en application des méthodes, concepts, définitions, normes, classifications et nomenclatures approuvés par le Comité technique des programmes statistiques
- Préparer les dossiers à soumettre aux réunions du Conseil national de la statistique et du Comité technique des programmes statistiques
- Assurer le secrétariat et l'organisation des réunions du Conseil national de la statistique et du Comité technique des programmes statistiques ainsi que de ses sous-comités sectoriels
- Réaliser des enquêtes d'inventaire à couverture nationale notamment les recensements généraux de la population ceux des entreprises.
- Produire les comptes nationaux
- Suivre la conjoncture et la prévision économiques en rapport avec le service en charge de la prévision et de la conjoncture économique
- Elaborer et de gérer les fichiers des entreprises et des localités
- Elaborer les indicateurs économiques, sociaux et démographiques
- Centraliser et de diffuser les synthèses des données statistiques produites par l'ensemble du système statistique national
- Favoriser le développement des sciences statistiques et la recherche économique appliquée relevant de sa compétence
- Promouvoir la formation du personnel spécialisé pour le fonctionnement du système national d'information statistique par l'organisation des cycles de formation appropriés notamment au sein d'une école à vocation régionale ou sous régionale intégrée à l'agence.

Dans les différentes régions, l'ANSD est représentée par 14 Services régionaux de la Statistique et de le Démographie (SRDS) qui sont sous La Direction de l'Action Régionale (DAR) chargée de gérer le personnel, le matériel et les moyens financiers des services tout en coordonnant et animant le système statistique régional.

1.1.2 Organisation de l'agence

La Direction générale comprend, le Directeur général, le Directeur général adjoint, les Conseillers techniques, l'Auditeur interne, la Cellule du Contrôle de

gestion, la Cellule de passation des marchés, la Cellule de communication, la Cellule juridique, la Cellule de gestion des partenariats, le Service de sécurité, le Service médical et les secrétariats du Directeur général et du Directeur général adjoint. Un Bureau de l'archivage et du courrier y est rattaché pour la gestion des archives et des courriers à l'arrivée et au départ de l'Agence. En dehors de la direction générale, l'ANSD compte 8 directions à savoir :

- La Direction des Statistiques Economiques et de la Comptabilité nationale (DSECN) ;
- La Direction des Statistiques démographiques et sociales (DSDS) ;
- La Direction des Systèmes d'Information et de la Diffusion (DSID)
- La Direction de l'Administration Générale et des Ressources Humaines (DA-GRH)
- La Direction de l'École Nationale de la Statistique et de l'Analyse Économique (ENSAE)
- La Direction de la Méthodologie, de la Coopération statistique et de l'Innovation (DMCI)
- La Direction de l'Action Régionale (DAR)
- L'agence comptable

1.2 Présentation de la DMCI

La Direction de la Méthodologie, de la Coordination Statistique et de l'Innovation (DMCI) est une direction récente. Elle a remplacé la Direction de la Méthodologie, de la Coordination statistique et des Partenariats (DMCP). Ce changement de dénomination de la direction est survenu à l'issu d'une réorganisation de l'organigramme de l'agence qui a eu lieu le 15 Juin 2023. Ces révisions se justifient par la perpétuelle quête de l'ANSD à s'arrimer aux standards internationaux et font tournés l'ANSD vers l'innovation. La DMCI élabore et vulgarise les méthodologies et les bonnes pratiques en matière statistique. Elle est notamment chargée d'harmoniser les concepts, nomenclatures et classification utilisés à l'ANSD et au sein de tout le Système statistique national. En outre, elle est chargée de la mise en place, progressive et de manière coopérative, d'un cadre national d'assurance qualité et d'assurer la veille technologique, de faire la promotion de la recherche et de l'innovation. La DMCI assure également la coordination et la programmation des activités statistiques du Système statistique national (SSN) et supervise la

coopération internationale de l'ANSD. Elle sert d'interlocuteur entre l'ANSD et les autres structures membres du SSN. Elle appuie le Directeur général dans la préparation des dossiers relatifs au Conseil national de la Statistique (CNS) et au Comité technique des Programmes statistiques (CTPS), notamment la préparation des sessions de ses organes et des commissions et groupes de travail qu'ils mettent en place, le suivi de l'exécution de leurs décisions. Elle veille au maintien d'un niveau élevé de maîtrise des techniques statistiques et à la gestion de la qualité des résultats produits. La DMCI est structurée en deux divisions principales :

— La Division de la Méthodologie et de l'Innovation (DMI).

— La Division de la Coopération et de la Coordination Statistique (DCC).

1.2.1 Division de la Méthodologie et de l'Innovation (DMI)

La DMI est en charge de l'élaboration des méthodologies, nomenclatures et des classifications. Elle assure la mise en place d'un système d'assurance qualité et promeut la veille technologique ainsi que la recherche et l'innovation. Elle est composée de deux bureaux à savoir :

— Le Bureau des Méthodes et Normes (BMN)
  Ce bureau est responsable de l'élaboration et de la vulgarisation des méthodologies et normes, de la mise en œuvre du cadre national d'assurance qualité (CNAQ) et de la coordination de l'harmonisation méthodologique et gestion des visas statistiques.

— Le Bureau de la Recherche et de l'Innovation (BRI)
  Le BRI se charge de la veille technologique et de la promotion de l'innovation ainsi que de la coordination d'études approfondies et production de rapports.

1.2.2 Division de la Coopération et de la Coordination Statistique (DCC)

La DCC élabore les Stratégies Nationales de Développement de la Statistique (SNDS) et les Plans Stratégiques de Développement (PSD). Elle administre la plateforme PTA, réalise la cartographie du système statistique national et gère la coopération internationale. Elle comprend 2 bureaux à savoir

Le Bureau de la Coordination Statistique (BCS) dont les principales missions sont :

— D'élaborer et d'assurer le suivi et l'évaluation des SNDS et des PSD ;

— D'administrer la plateforme PTA et réaliser périodiquement la cartographie du SSN ;

— D'assurer l'animation du Système statistique national avec l'organisation chaque année du CNS, des réunions du CTPS et les réunions des sous-comités ;

— D'administrer et d'animer le portail web du SSN et de réaliser chaque année l'enquête de satisfaction des utilisateurs ;

— D'identifier et de mettre en œuvre en collaboration avec l'ENSAE ou d'autres structures, des renforcements de capacité au bénéfice de tout le SSN.

Le Bureau de la Coopération Internationale (BCI) dont les tâches consistent :

— Au suivi des indicateurs ODD et adhésion aux normes internationales (NSDD, NSDD Plus) ;

— A la gestion des partenariats internationaux avec des institutions comme UNSD, PARIS21, et AFRISTAT.

1.3 Bilan du stage

Le stage s'est déroulé du lundi 05 aout 2024 au jeudi 03 octobre 2024 au bureau de la recherche et de l'innovation. Cette immersion nous a permis de nous imprégner du monde professionnel, d'en saisir les attitudes requises dans ce milieu afin de servir au mieux. Les tâches réalisées au cours de ce stage se scindent en 2 points. Le premier point consistait en la conception d'une application d'automatisation des procédures d'échantillonnage dénommée « SamPower ». Cette activité nécessitait des connaissances en programmation python, développement d'application web et en techniques de sondage, ce qui nous a permis de nous familiariser avec les outils de développement d'application web et surtout de mettre en pratique les connaissances acquises notamment sur les sondages, la programmation python et les statistiques descriptives au cours de nos 2 premières années d'études à l'ENSAE. Le second point consistait essentiellement en la participation aux tâches courantes du bureau notamment la correction de questionnaire d'enquête ainsi qu'aux différentes présentations des projets innovants qui y sont en cours de développement.

Chapitre

2 Définitions et méthodologie des sondages

Ce chapitre est consacré essentiellement aux définitions des concepts utilisés dans les sondages d'une part et de décrire le processus complet d'une enquête par sondage d'autre part.

Avant d'aborder les détails méthodologiques liés aux sondages, il est essentiel de définir clairement les principaux concepts utilisés dans le domaine. Pour les besoins du chapitre nous allons considérer un cas d'étude que nous utiliserons tout le long du travail. Un cabinet statistique souhaite connaitre le chiffre d'affaires moyen des entreprises du Sénégal au nombre de N. Il réalise une enquête statistique sur n entreprises avec un questionnaire comportant k variables.

2.1 Définition et processus du sondage

2.1.1 Définition des concepts

Population

La population fait référence à l'ensemble des unités sur lesquelles porte l'étude. Elle représente l'ensemble des individus ou des éléments ayant une ou plusieurs caractéristiques communes et sur lesquels on souhaite obtenir des informations. Dans notre cas d'étude, la population est l'ensemble des entreprises du Sénégal.

Base de sondage

La base de sondage est une liste ou une représentation de l'ensemble des unités composant la population cible. Elle sert de cadre de référence pour sélectionner l'échantillon. Elle doit être exhaustive, c'est-à-dire inclure toutes les unités de la population sans doublons ni omissions. Une mauvaise base de sondage peut introduire des biais de sélection qui compromettent la représentativité de l'échantillon. Dans le cas d'étude, la base de sondage pourrait être une base des entreprises obtenue lors du Recensement Général des Entreprises (RGE) au Sénégal.

Plan de sondage

Le plan de sondage désigne l'ensemble des procédures et techniques utilisées pour sélectionner l'échantillon dans la population. Il comprend le choix de la méthode d'échantillonnage, la taille de l'échantillon, ainsi que l'expression de l'estimateur. Un bon plan de sondage doit garantir que l'échantillon soit représentatif de la population, tout en tenant compte des contraintes de temps, de budget, et de précision souhaitée.

Echantillon

L'échantillon constitue l'ensemble des unités qui ont été sélectionnées pour répondre aux questions. Il est tiré selon plusieurs méthodes ou techniques, que nous aborderons dans le chapitre suivant, en fonction des besoins de l'étude. Dans notre cas d'étude, l'échantillon est l'ensemble des n entreprises qui seront sélectionnées pour participer à l'enquête.

Sondage

Le sondage statistique est une technique qui consiste à enquêter sur un phénomène auprès d'un échantillon d'individus sélectionné selon certaines règles scientifiques pour représenter toute la population dont ils sont issus (AFRISTAT). Il repose sur une approche inférentielle, ce qui signifie que les résultats obtenus à partir de l'échantillon sont utilisés pour estimer les caractéristiques de la population entière. Cette méthode est largement utilisée en raison de ses avantages en termes de coût, de rapidité et de faisabilité.

2.1.2 Processus d'élaboration d'un sondage

Le processus d'un sondage peut être divisé en plusieurs étapes clés, chacune ayant son importance pour garantir la qualité des données recueillies et des résultats obtenus.

Définition des objectifs de l'étude

Avant de commencer un sondage, il est crucial de définir clairement les objectifs de l'étude à savoir par exemple les types d'informations recherchés, les problèmes à résoudre. Cette étape permet de guider le reste du processus et d'assurer que les données collectées seront pertinentes et utiles. Dans le cas d'étude, les objectifs de l'étude peuvent être par exemple de déterminer le chiffre d'affaires moyen des entreprises, de connaître le chiffre d'affaires des entreprises en fonction de leur répartition sur le territoire et de leur secteur d'activité.

Définition de la population cible

Il est essentiel de bien identifier la population étudiée. Il peut s'agir d'une population géographique, démographique ou temporelle. Une définition précise de la population cible aide à orienter la sélection de l'échantillon et à établir les bases de sondage.

Création de la base de sondage

La base de sondage doit inclure toutes les unités de la population cible pour minimiser le risque d'erreurs de couverture. La qualité de la base de sondage est cruciale pour assurer la représentativité de l'échantillon. Une base de sondage bien conçue garantit que l'échantillon sera à la fois représentatif et complet.

Choix de la méthode d'échantillonnage

La méthode d'échantillonnage doit être adaptée aux objectifs de l'étude et à la structure de la population. Les principales méthodes d'échantillonnage ainsi que les critères pour les choisir seront abordées dans le chapitre suivant.

Calcul de la taille de l'échantillon

La taille de l'échantillon dépend de plusieurs paramètres qui seront choisis par l'enquêteur en fonction de ses besoins et des informations dont il dispose.

Les différents paramètres seront expliqués dans le chapitre suivant ainsi que les formules de calcul de la taille.

Collecte des données

Les données sont collectées auprès des unités sélectionnées, souvent à l'aide de questionnaires, d'interviews, ou d'observations directes. Une attention particulière doit être portée à l'administration de l'enquête pour éviter les erreurs. Il est également essentiel de former les enquêteurs pour garantir la cohérence et la fiabilité des réponses.

Analyse des données

Une fois les données collectées, elles doivent être traitées et analysées. Cela implique de vérifier la qualité des données, de traiter les réponses manquantes, et de préparer les données pour l'analyse statistique. Diverses techniques statistiques peuvent être utilisées pour interpréter les résultats et répondre aux objectifs de l'étude.

Calcul des estimateurs

Les données recueillies sont utilisées pour calculer des estimateurs, qui sont des mesures statistiques permettant de décrire la population cible à partir de l'échantillon. Parmi les estimateurs les plus courants, on retrouve la moyenne, la proportion, la variance ou des indicateurs composés plus complexes.

Interprétation et communication des résultats

Après l'analyse, il est essentiel d'interpréter les résultats dans le contexte des objectifs initiaux. Les conclusions doivent être clairement formulées et présentées de manière à être compréhensibles pour le public cible, qu'il s'agisse de décideurs, de chercheurs ou du grand public. Les résultats doivent être accompagnés de recommandations basées sur les données analysées.

Évaluation du processus

Enfin, une évaluation du processus de sondage permet d'identifier les forces et les faiblesses de l'étude, d'apprendre des erreurs commises et d'améliorer les futures enquêtes. Cette étape est cruciale pour le perfectionnement des méthodes et

techniques utilisées dans le domaine du sondage.

2.2 Méthodologie

2.2.1 Présentation des différentes méthodes de sondage ou d'échantillonnage

Les méthodes de sondage sont essentielles pour collecter des données de manière structurée et représentative. Toutefois, il existe différentes approches, chacune avec ses avantages et ses inconvénients. Dans cette section, nous examinerons les méthodes non probabilistes et probabilistes de sélection d'échantillons, en détaillant leurs principes, leurs applications et leurs techniques de tirage.

Les sondages non probabilistes

Les sondages non probabilistes sont souvent peu utilisés par les instituts nationaux de statistique en raison de leur caractère subjectif. L'enquêteur joue un rôle central dans le processus de sélection de l'échantillon, ce qui rend cette technique rapide et facile à mettre en œuvre. De plus, elle ne nécessite pas de base de sondage préalable, ce qui contribue à sa simplicité. Cette approche est souvent choisie pour plusieurs raisons comme des études exploratoires ou qualitatives, des enquêtes auprès des groupes spécifiques et difficiles à atteindre ou pour la recherche en marketing.
Il existe plusieurs techniques de tirage dans les sondages non probabilistes notamment le tirage à l'aveuglette, le tirage à participation volontaire, le tirage au jugé et le tirage par quota qui est la plus connue des sondages non probabilistes. Elle est similaire au sondage stratifié, car elle choisit l'échantillon en se basant sur la distribution de la population selon une ou plusieurs variables.

Les sondages probabilistes

Les sondages probabilistes sont conçus pour garantir que chaque individu de la base de sondage ait une probabilité connue d'être sélectionné. Ces techniques sont plus rigoureuses et offrent des résultats plus fiables. Les sondages probabilistes reposent sur un principe fondamental : chaque individu de la population doit avoir une chance connue d'être inclus dans l'échantillon, ce qui est appelé la probabilité

d'inclusion. Cette probabilité dépend de la méthode d'échantillonnage qui sera choisie. Cette approche nécessite une base de sondage à partir de laquelle l'échantillon sera tiré.

Les sondages probabilistes sont plus complexes, demandent plus de temps et sont généralement plus coûteux que les méthodes non probabilistes mais ils présentent des avantages significatifs tels que la possibilité de faire des inférences sur la population. Ces techniques de tirage sont nombreuses et présentes toutes des avantages et des inconvénients selon l'étude. Nous allons présenter les 4 plus utilisées, tout en précisant que nous en retiendrons deux pour les besoins de l'application.

Le sondage aléatoire simple

Chaque membre de la population a une chance égale d'être sélectionné. C'est la méthode la plus basique et la plus intuitive pour constituer un échantillon. Les individus sont tirés aléatoirement pour la constitution de l'échantillon.

Le sondage stratifié

Cette méthode consiste à diviser la population en sous-groupes homogènes appelés strates avant de procéder à un échantillonnage aléatoire dans chaque strate. Cela garantit que tous les segments de la population sont représentés dans l'échantillon final. Les sondages aléatoires simple et stratifié seront détaillés dans le point suivant.

Le sondage systématique

Dans cette approche, un point de départ est choisi au hasard à la suite de quoi chaque k-ième membre de la population est sélectionné avec k représentant le pas. Le pas correspond au rapport entre les tailles de la population et de l'échantillon (k= N/n). Cette méthode est simple à mettre en œuvre, mais il faut veiller à ce que la population ne présente une périodicité qui pourrait biaiser les résultats.

Le sondage par grappe

Cette méthode consiste à diviser la population en groupes appelés grappes et à sélectionner aléatoirement certaines grappes. Les grappes doivent être constituées de sorte à obtenir une homogénéité entre les groupes et une hétérogénéité dans chaque groupe. Ensuite, tous les membres des grappes sélectionnées sont inclus dans l'échantillon. C'est une méthode efficace pour réduire les coûts et le temps de collecte des données, surtout lorsque la population est géographiquement dispersée.

2.2.2 Sondage aléatoire simple

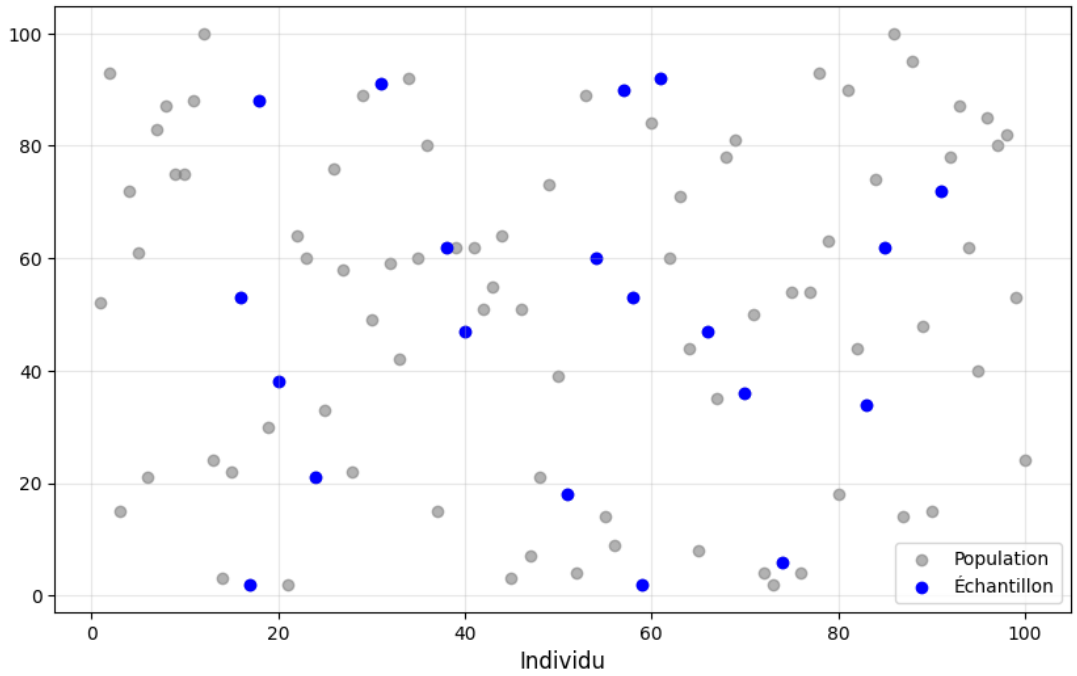
Définition et mise en œuvre

Il s'agit d'une méthode d'échantillonnage dans laquelle chaque membre d'une population a une probabilité égale et connue d'être inclus dans l'échantillon. Il existe 2 types à savoir le sondage aléatoire simple avec remise et celui sans remise. Le sondage aléatoire simple est le plus utilisé en pratique car il donne une plus faible variance de l'estimateur que le sondage aléatoire simple avec remise. Nous considérerons dans notre travail celui sans remise. Pour ce dernier, la probabilité d'inclusion correspond au rapport de la taille de l'échantillon sur la taille de la population $\pi = n/N$. Il existe donc

$$\binom{N}{n} = \frac{N!}{n!\,(N-n)!}$$

échantillons possibles. La sélection est généralement effectuée à l'aide d'un générateur de nombres aléatoires ou par un tirage au sort dans une urne à 10 boules ou de tirage de nombres aléatoires suivant une loi. La figure suivante illustre bien cette méthode de tirage.

FIGURE 2.1 – *Illustration du sondage aléatoire simple*



Source : *Auteur, données générées aléatoirement*

Avantages du sondage aléatoire simple

Le sondage aléatoire simple présente plusieurs avantages :

— Équité et impartialité : Chaque membre de la population a une chance égale d'être sélectionné, ce qui réduit les biais de sélection.

— Facilité d'implémentation : Le processus de sélection est simple et peut être facilement automatisé à l'aide de logiciels statistiques ou de générateurs de nombres aléatoires, ce qui rend cette méthode accessible même pour les chercheurs avec peu d'expérience.

— Possibilité d'estimation de l'erreur d'échantillonnage : Étant donné que chaque unité de la population a une probabilité connue d'être incluse dans l'échantillon, il est possible de calculer l'erreur d'échantillonnage, permettant d'évaluer la fiabilité des résultats.

— Simplicité des analyses statistiques : Les données recueillies par cette méthode peuvent être analysées à l'aide de nombreuses techniques statistiques classiques, facilitant l'interprétation des résultats.

Limites

Malgré ses avantages, le sondage aléatoire simple présente certaines contraintes comme :

— La difficulté d'accès à une base de sondage complète : Pour effectuer un sondage aléatoire simple, il est nécessaire de disposer d'une base de sondage exhaustive et précise. Dans la pratique, cela peut être difficile, en particulier dans les populations peu connues ou sous-représentées.

— Le coût et le temps : La collecte de données auprès d'un échantillon aléatoire peut nécessiter des ressources considérables, notamment du temps et des financements, surtout si la population est dispersée géographiquement.

— La variabilité des échantillons : Même avec une méthode de sélection aléatoire, il est possible d'obtenir des échantillons qui ne reflètent pas parfaitement les caractéristiques de la population. Cela peut nécessiter des ajustements ou des stratifications supplémentaires pour améliorer la représentativité.

Détermination de la taille de l'échantillon

Dans un sondage aléatoire, la taille de l'échantillon joue un rôle très important dans la précision des résultats. En effet, une grande taille peut améliorer la précision

mais la question du coût de l'enquête peut survenir. Il y a donc deux techniques pour déterminer la taille de l'échantillon.

Une forte contrainte de coût : dans ce cas la taille est égale au rapport du budget par le coût unitaire d'un questionnaire ($n = B/c$ avec B le budget et c le coût de chaque questionnaire)

Une faible contrainte de cout qui permet alors de se focaliser sur l'amélioration de la précision des résultats. Dans ce cas, la taille est déterminée en fonction de la marge d'erreur ε avec un niveau de confiance de $1-\alpha$. On distingue alors 2 cas possibles :

— Le paramètre à estimer est une moyenne

On obtient :

Pour déterminer la taille n de l'échantillon sous contrainte de précision, on a :

$$P(|\hat{\mu} - \mu| \leq \varepsilon) = 1 - \alpha$$

Cela revient à écrire :

$$P\left(-\frac{\varepsilon}{\sqrt{V(\hat{\mu})}} \leq \frac{\hat{\mu} - \mu}{\sqrt{V(\hat{\mu})}} \leq \frac{\varepsilon}{\sqrt{V(\hat{\mu})}}\right) = 1 - \alpha$$

En utilisant la loi normale centrée réduite, on obtient :

$$P\left(-\frac{\varepsilon}{\sqrt{V(\hat{\mu})}} \leq \mathcal{N}(0,1) \leq \frac{\varepsilon}{\sqrt{V(\hat{\mu})}}\right) = 1 - \alpha$$

Ce qui implique que :

$$\frac{\varepsilon}{\sqrt{V(\hat{\mu})}} = q_{\alpha/2}$$

Ainsi, la variance est donnée par :

$$V(\hat{\mu}) = \frac{(1 - \frac{n}{N})S^2}{n}$$

et on a finalement :

$$\frac{\varepsilon}{\sqrt{\frac{(1-\frac{n}{N})S^2}{n}}} = q_{\alpha/2}$$

En résolvant cette équation, on obtient la taille n de l'échantillon :

$$n = \frac{q^2_{\alpha/2} S^2}{\varepsilon^2 + \frac{q^2_{\alpha/2} S^2}{N}}$$

où :

- ε est la marge d'erreur,
- S^2 est la variance estimée,
- N est la taille de la population,
- $q_{\alpha/2}$ est le quantile de la loi normale pour un niveau de confiance $1-\alpha$.

— Le paramètre à estimer est une proportion

Pour estimer une proportion p avec une précision donnée ε, on impose que :

$$P(|\hat{p}-p| \leq \varepsilon) = 1-\alpha$$

Cela revient à écrire :

$$P\left(-\frac{\varepsilon}{\sqrt{V(\hat{p})}} \leq \frac{\hat{p}-p}{\sqrt{V(\hat{p})}} \leq \frac{\varepsilon}{\sqrt{V(\hat{p})}}\right) = 1-\alpha$$

En supposant que $\hat{p}$ suit une loi normale, et en utilisant la loi normale centrée réduite, on obtient :

$$P\left(-\frac{\varepsilon}{\sqrt{V(\hat{p})}} \leq \mathcal{N}(0,1) \leq \frac{\varepsilon}{\sqrt{V(\hat{p})}}\right) = 1-\alpha$$

Ce qui implique que :

$$\frac{\varepsilon}{\sqrt{V(\hat{p})}} = q_{\alpha/2}$$

La variance de $\hat{p}$ est donnée par :

$$V(\hat{p}) = \frac{p(1-p)}{n}$$

Ainsi, en isolant n, on obtient la taille de l'échantillon :

$$n = \frac{q_{\alpha/2}^2 p(1-p)}{\varepsilon^2}$$

Dans le cas d'une population finie de taille N, la formule est ajustée en tenant compte du facteur de correction pour population finie :

$$n = \frac{q_{\alpha/2}^2 p(1-p)}{\varepsilon^2 + \frac{q_{\alpha/2}^2 p(1-p)}{N}}$$

Paramètres utilisés

— p : la proportion à estimer,

— $\hat{p}$: l'estimation de la proportion,

— ε : la marge d'erreur,

— $q_{\alpha/2}$: le quantile de la loi normale pour un niveau de confiance $1-\alpha$,

— N : la taille de la population (si connue),

— n : la taille de l'échantillon.

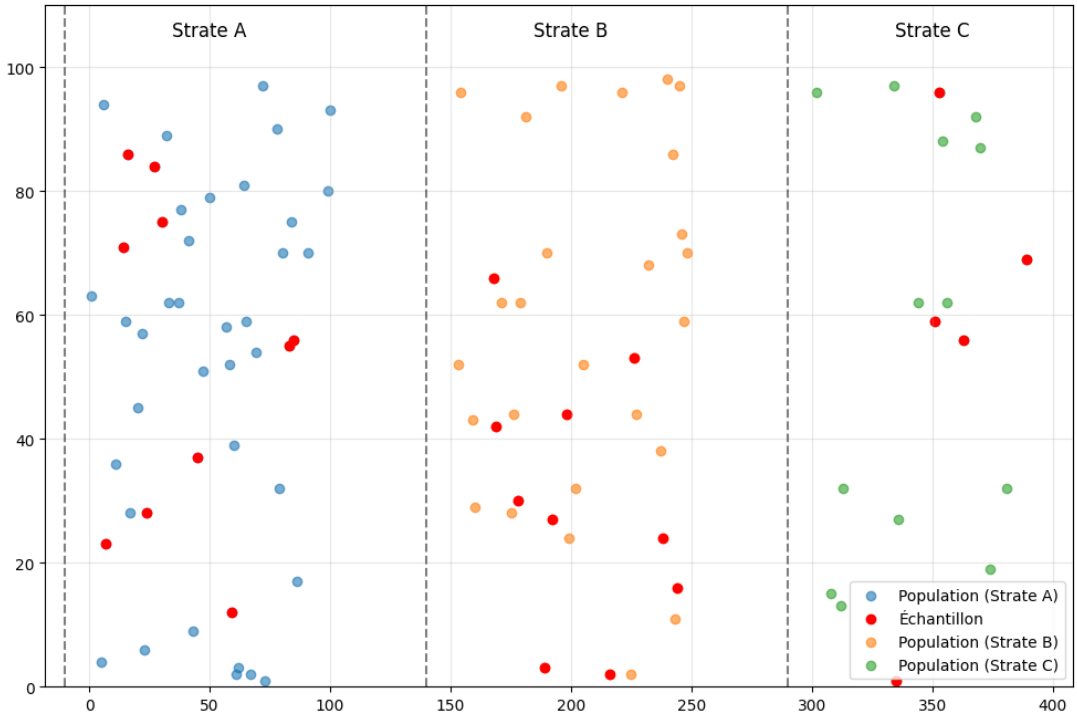
Si la proportion p est inconnue, on prend souvent une valeur prudente de $p = 0.5$, car elle maximise le produit $p(1-p)$ et donc la taille n.

2.2.3 Sondage stratifié

Définition

Le sondage stratifié consiste à diviser la population en sous-groupes distincts, appelés strates, qui partagent des caractéristiques communes. Ces strates peuvent être basées sur des critères tels que l'âge, le sexe, le revenu, la région géographique, ou d'autres variables d'intérêt. Ensuite, un échantillon aléatoire est prélevé au sein de chaque strate comme l'illustre la figure ci dessous.

FIGURE 2.2 – *Illustration du sondage stratifié*



Source : *Auteur, données générées aléatoirement*

Avantages

Le sondage stratifié présente plusieurs avantages :

— Amélioration de la précision : En s'assurant que chaque sous-groupe est représenté, le sondage stratifié réduit la variabilité des estimations. Les résultats obtenus à partir de cet échantillon sont donc généralement plus précis que ceux obtenus par un échantillon aléatoire simple.

— Flexibilité d'échantillonnage : Les chercheurs peuvent choisir la taille de l'échantillon pour chaque strate en fonction de son importance ou de sa variabilité, ce qui permet d'adapter l'étude aux besoins spécifiques.

— Possibilité d'analyse des sous-groupes : Les résultats peuvent être analysés non seulement au niveau global, mais aussi par strate, permettant ainsi de tirer des conclusions significatives pour chaque sous-groupe.

Limites

Le sondage stratifié comporte également certaines limites :

— Complexité de mise en œuvre : La définition des strates appropriées nécessite une bonne connaissance de la population et peut être complexe à mettre en œuvre. Une stratification incorrecte peut conduire à des biais ou à une mauvaise interprétation des résultats.

— Nécessité de données préalables : Pour créer des strates efficaces, il est souvent nécessaire de disposer de données préalables sur la population. Si ces données ne sont pas disponibles, cela peut compliquer voire rendre impossible le processus d'échantillonnage.

— Coût et temps : La collecte de données au sein de plusieurs strates peut nécessiter plus de temps et de ressources financières que le sondage aléatoire simple, en raison de la nécessité de gérer et d'analyser plusieurs groupes distincts.

— Risques de biais au sein des strates : Si les sous-groupes ne sont pas homogènes ou s'ils contiennent des variations internes importantes, les résultats peuvent encore être biaisés. Par exemple, si une strate est composée d'individus très divers en termes d'opinions ou de comportements, cela peut affecter la validité des résultats.

Détermination de la taille de l'échantillon

La détermination de la taille de l'échantillon dans le cas d'un sondage stratifié peut se faire de 2 façons différentes. La première façon consiste à calculer la taille de l'échantillon total puis de faire une allocation dans chaque strate. Cette allocation peut être proportionnelle ou de Neyman (optimale). Dans notre travail, nous nous sommes uniquement intéressés à l'allocation proportionnelle. Cette méthode consiste à répartir la taille de l'échantillon selon la même structure de répartition de l'effectif de la population dans les strates. Dans notre cas d'étude considérons une variable de stratification « effectif des salariés » avec h modalités. Considérons N_h la population dans la strate h et n_h le nombre d'individus de l'échantillon appartenant à la strate h. On a la relation suivante :

$$\frac{n_h}{n} = \frac{N_h}{N} \Rightarrow n_h = n \cdot \frac{N_h}{N}.$$

La seconde manière consiste à calculer une taille d'échantillon dans chaque strate. Cela permet d'obtenir des résultats avec plus de précision mais aussi une taille d'échantillon beaucoup plus grande que la méthode par allocation proportionnelle.

Chapitre

3 Présentation de l'application

Dans ce chapitre nous ferons la présentation de l'application et de ses fonctionnalités en passant par son architecture.

3.1 Justification de l'application

La création d'une application dédiée à la gestion des procédures d'échantillonnage représente une réponse efficace aux défis rencontrés par les personnes physique ou morale réalisant des enquêtes. Plusieurs raisons justifient le développement d'une telle application.

3.1.1 Accessibilité du tirage de l'échantillon

L'application vise à rendre les procédures d'échantillonnage accessible à un public plus large, qui n'a pas nécessairement une formation approfondie en statistiques. Le calcul de la taille optimale de l'échantillon ainsi que le tirage nécessitent une connaissance sur les notions en sondage. Grâce à une interface intuitive, les utilisateurs peuvent effectuer des calculs pour déterminer la taille de l'échantillon et sélectionner des échantillons adaptés à leur méthode d'enquête. Cela favorise une démocratisation des sondages, permettant ainsi à davantage de personnes de contribuer à la production de statistiques fiables.

3.1.2 Gain de temps et d'efficacité

La collecte et l'analyse des données peuvent être des processus longs et laborieux. En automatisant la sélection des échantillons et les calculs des tailles d'échantillon, l'application réduit considérablement le temps nécessaire à ces étapes. Les utilisateurs peuvent ainsi se concentrer sur la conception de leurs sondages, l'analyse et l'interprétation des résultats, entraînant une augmentation de l'efficacité dans le processus de l'enquête.

3.1.3 Réduction des erreurs de calcul

Les erreurs de calcul peuvent avoir des conséquences significatives sur les résultats d'une étude. En utilisant une application automatisée, le risque d'erreurs humaines est considérablement réduit, garantissant des calculs précis concernant la taille de l'échantillon et la sélection de l'échantillon selon la méthode choisie.

3.2 Présentation de l'application SamPower

SamPower (sampowerv1.streamlit.app) est une application destinée à faciliter les études statistiques en calculant les tailles d'échantillons optimales pour différents types d'enquêtes. Elle va au-delà des calculs en permettant également la sélection automatisée de l'échantillon, selon des méthodes spécifiques : le sondage aléatoire simple et le sondage stratifié. SamPower a été créé dans le but de rendre les processus d'échantillonnage plus accessibles et précis, en réduisant les risques d'erreur manuelle et en garantissant une meilleure fiabilité des résultats d'enquête.

3.3 Description des fonctionnalités

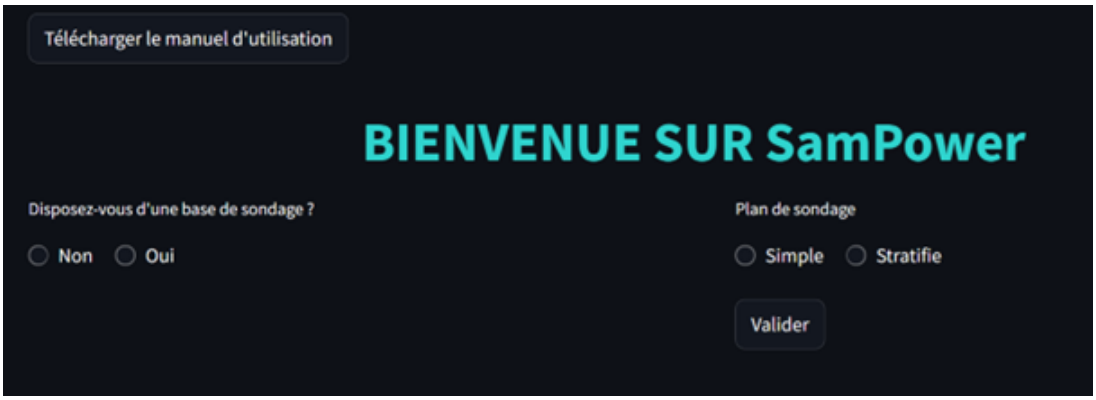
L'application a 2 fonctionnalités principales à savoir en premier lieu le calcul des tailles d'échantillon en prenant en compte des paramètres spécifiques tels que la taille de la population, marge d'erreur, niveau de confiance, proportion ou moyenne estimée, le taux de réponse, l'effet de plan et la variable de stratification pour fournir une taille d'échantillon adaptée à l'enquête puis en second lieu la sélection de l'échantillon. L'application permet à l'utilisateur de tirer un échantillon après avoir fait le calcul de la taille si ce dernier disposait d'une base de sondage. La sélection se fait selon la méthode de sondage aléatoire simple ou il est généré aléatoirement des participants à partir d'une liste complète et la méthode de sondage

stratifié ou la sélection des unités en fonction des proportions des strates. Dans la suite de cette section, nous vous décrirons les étapes d'utilisation de l'application.

3.3.1 Etape 1 : Choix de la méthode et de la base de sondage

Lorsque l'utilisateur lance l'application, il doit sélectionner la méthode de tirage qu'il souhaite utiliser et spécifier s'il dispose d'une base de sondage. Le cas échéant, la taille de sa population sera le nombre d'individus de la base de sondage. Il a également la possibilité de télécharger le manuel d'utilisation de l'application qui décrit toutes les étapes pour une utilisation optimale de l'application.

FIGURE 3.1 – *Page d'accueil de SamPower*



Source : *Calculs de l'auteur*

3.3.2 Etape 2 : Choix des paramètres

Cas du sondage aléatoire simple

L'utilisateur choisit d'abord le paramètre à estimer (proportion ou moyenne). Ce choix est fait en fonction de la variable d'intérêt principale de l'enquête. Dans notre cas d'étude, le paramètre à estimer correspondra à la moyenne car on s'intéresse au chiffre d'affaires moyen. Les paramètres à entrer sont :

— Paramètre estimé : Cela correspond à une valeur de la proportion ou de l'écart-type dont on dispose soit d'une enquête précédente ou de l'enquête pilote effectuée. Pour la proportion, en cas d'indisponibilité d'une valeur, elle doit être fixée à 50 %.

— La marge d'erreur représente une plage autour de l'estimation (comme une moyenne ou un pourcentage) dans laquelle on s'attend à ce que la vraie valeur de la population se situe avec un certain niveau de confiance.

— Le niveau de confiance correspond au degré de certitude que l'on attribue à une estimation basée sur un échantillon.

— Le taux de réponse correspond à la proportion de personnes qui seront tirés et qui répondront aux questions.

— L'effet de plan ou de sondage est un concept utilisé pour mesurer l'impact d'un plan d'échantillonnage complexe (stratifié, en grappe, systématique) sur la précision des estimations par rapport à un échantillonnage aléatoire simple. Cet effet quantifie dans quelle mesure le plan d'échantillonnage augmente ou réduit la variance des estimations par rapport à celle obtenue avec un échantillon aléatoire simple de même taille.

FIGURE 3.2 – *Sondage aléatoire simple*



Source : *Calculs de l'auteur*

Cas du sondage stratifié

En plus des paramètres du sondage aléatoire simple, 2 paramètres s'ajoutent au sondage stratifié. Ce sont :

— Le type de sondage stratifié : il y a le sondage stratifié avec allocation proportionnelle et le calcul par strate.

— La variable de stratification : C'est la variable dont les modalités constitueront les strates de la population. Sans l'existence d'une base de sondage, l'utilisateur a la possibilité de définir elle-même une variable de stratification avec les différentes modalités ainsi que les tailles de chaque strate.

FIGURE 3.3 – *Sondage stratifié*



Source : *Calculs de l'auteur*

Une description de chaque paramètre est faite dans la touche « en savoir plus . . . » pour faciliter la compréhension à l'utilisateur.

3.3.3 Etape 3 : Téléchargement des résultats

Après avoir rempli les paramètres et lancer le calcul, les résultats s'affichent à la suite des paramètres. Il est composé de 2 parties obligatoires et une partie facultative à savoir

- Le résultat du calcul ;
- Le bouton de téléchargement du rapport ;
- Le bouton de téléchargement (facultatif) de la base de l'échantillon si l'utilisateur avait chargé une base de sondage.

3.4 Architecture de l'application

L'application SamPower a été développée avec le Framework Streamlit et la bibliothèque Samplics.

3.4.1 Streamlit

Streamlit est un Framework open-source en Python conçu pour le développement rapide et interactif d'applications web destinées principalement aux analyses de

données, aux visualisations, et à l'intelligence artificielle. Il permet aux utilisateurs de transformer facilement des scripts Python en applications web conviviales, sans nécessiter de compétences avancées en développement web. Dans le cadre de l'application SamPower, Streamlit a été choisi pour :

— Offrir une interface utilisateur intuitive et interactive, adaptée à des utilisateurs non techniciens ;

— Faciliter l'intégration des calculs complexes et des visualisations de résultats dans une seule plateforme web ;

— Permettre un déploiement rapide et une accessibilité via un simple navigateur, sans installation complexe pour les utilisateurs finaux grâce au Streamlit Community cloud.

3.4.2 Samplics

Samplics est une bibliothèque Python spécialisée dans la gestion des enquêtes basées sur des échantillons complexes. Elle fournit des outils pour le calcul des tailles d'échantillons, la sélection des échantillons, la pondération, et l'estimation des paramètres de population, tout en s'adaptant aux méthodologies modernes d'échantillonnage. Il a été développé par le sénégalais Mamadou S. Diallo. Cette bibliothèque intègre :

— Des méthodes variées d'échantillonnage, comme le sondage aléatoire simple, la sélection systématique et les techniques proportionnelles à la taille.

— Des techniques avancées d'estimation.

— Des outils de pondération permettant d'ajuster les poids pour compenser les biais liés à la non-réponse ou à d'autres imperfections du plan d'échantillonnage.

Chapitre

4 Cas d'utilisation de SamPower

Dans ce chapitre nous démontrons l'utilisation de SamPower pour réaliser une enquête statistique en suivant un processus structuré et détaillé. L'objectif est d'évaluer les performances de l'application dans la sélection d'échantillon.

4.1 Présentation de la base de sondage

La base de sondage utilisée est une partie de la base de l'Enquête harmonisée sur les Conditions de Vie des Ménages (EHCVM 2021) au Sénégal. Elle comprend des informations sur 7120 individus avec les variables suivantes :

TABLEAU 4.1 – Description des variables

Variable	Type	Description
region	Catégorielle	14 régions du Sénégal
milieu	Catégorielle	Le milieu de résidence
dem_hgender	Catégorielle	Le genre de l'individu
dem_hmstat	Catégorielle	La situation matrimoniale de l'individu
dem_heduc	Catégorielle	Le niveau d'éducation de l'individu
dem_branch	Catégorielle	La branche d'activité de l'individu
pauvre	Entier	La situation de pauvreté de l'individu

Source : *Données EHCVM 2021, Calculs de l'auteur*

4.1.1 Echantillonnage avec SamPower

Pour ce cas pratique, la variable d'intérêt est la variable « pauvre » avec pour modalités 1 si l'individu est pauvre et 0 sinon. La méthode de tirage utilisée sera le tirage aléatoire simple. Les paramètres que nous allons utiliser sont :

- La proportion estimée de la pauvreté dans la population : dans ce cas pratique, nous l'estimons à 33% car nous disposons de cette information dans notre base de sondage ;
- Le niveau de confiance est de 95% ;
- Un taux de réponse de 90% ;
- Une marge d'erreur de 3% ;
- Un effet de plan de 1 ;
- Une taille de population de 7120 individus.

Suite au calcul, une taille d'échantillon de 926 individus a été trouvée et 100 échantillons aléatoires simples ont été tirés.

4.2 Vérification de la représentativité des échantillons tirés avec samPower

Dans cette section, nous évaluons la représentativité des échantillons générés à l'aide de l'application par rapport à la population de référence. Pour ce faire, 100 échantillons distincts ont été extraits de la population en utilisant les mêmes paramètres décrits précédemment. L'objectif est de déterminer dans quelle mesure ces échantillons diffèrent de la population selon la variable d'intérêt, "pauvre". Cette variable servira de référence pour juger de la fidélité des échantillons par rapport à la population cible.

4.2.1 Méthodologie

Dans le cadre de cette étude, après avoir extrait 100 échantillons distincts de la population, nous avons calculé l'erreur quadratique moyenne (EQM) pour évaluer les écarts entre les proportions de pauvres dans les échantillons et celle observée dans la population. Cette mesure permet d'estimer la représentativité des échantillons par rapport à la population cible en se basant sur la variable d'intérêt, "pauvre".

L'erreur quadratique moyenne est définie comme la moyenne des carrés des écarts entre la proportion des pauvres dans chaque échantillon p_i et la proportion des pauvres dans la population P. La formule de l'EQM est donnée par :

$$\text{EQM} = \frac{1}{n}\sum_{i=1}^{n}(p_i - P)^2$$

où :

— n est le nombre total d'échantillons (dans ce cas, $n = 100$),

— p_i est la proportion des pauvres dans l'échantillon i,

— P est la proportion des pauvres dans la population.

Cette méthodologie permet d'obtenir une estimation quantitative des écarts entre les échantillons et la population, permettant ainsi l'évaluation de la représentativité des échantillons générés.

4.2.2 Résultats et interprétation

L'erreur quadratique moyenne (EQM) calculée est de $0,00025$. Cette valeur, étant extrêmement proche de zéro, indique que les échantillons tirés sont, en moyenne, représentatifs de la population de référence.

Ces résultats confirment la fiabilité de l'application, tant pour le calcul de la taille des échantillons que pour le processus de tirage, garantissant ainsi une représentativité adéquate des échantillons générés.

Conclusion

L'objectif de ce document était de présenter l'application d'automatisation des procédures d'échantilonnage SamPower. Cet outil a été développé lors du stage d'immersion réalisé en fin de 2è année du cycle AS.
Dans un premier temps, il s'est agit de présenter la structure dans laquelle le stage a été effectué avant de définir les concepts rencontrés en sondage et de donner les méthodologies de ces techniques. Dans un second temp, l'application a été présenté et un cas pratique a été réalisé pour vérifier son efficacité.
L'application SamPower permet a l'utilisateur d'effectuer les calculs des tailles d'échantillon sur une interface conviviale et intuitive en ayant à sa disposition quelques paramètres comme la marge d'erreur, le niveau de confiance, l'effet de plan et le taux de réponse. Elle permet également de tirer un échantillon en fonction de la méthode de tirage choisie entre le tirage aléatoire simple et le tirage stratifié.
Le cas pratique réalisé a montré que les estimations faites sur l'échantillon ne sont pas significativement différentes des paramètres de la population. Cela montre une bonne représentativité de l'échantillon sur la population.
L'application étant à sa première version ne prend pas encore en charge les méthodes d'échantillonnage systématique ou en grappes. En perspective, elle peut être mise à jour pour prendre en compte :

— l'intégration d'autres méthodes d'échantillonnage (systématique, en grappes) ;
— L'ajout d'une visualisation graphique des données et des échantillons sélectionnés ;
— L'ajout des accès personnalisés pour les employés de l'ANSD

En somme, cet outil pourrait faciliter les procédures d'échantillonnage pour les non statisticiens, les rendre plus rapides tout en donnant des résultats fiables pour effectuer de bonnes estimations.

Bibliographie

[1] Afristat. (2023). Théorie et pratique des sondages. Programme de renforcement des systèmes statistiques nationaux des pays du G5 Sahel dans le cadre de la redevabilité de l'Alliance Sahel.

[2] ANSD. (2022). Projet de décision abrogeant et remplaçant les articles 2, 3, 6, 15, 16 et 17 de la décision n°01335/MEPC/ANSD/DG du 29 mars 2022 fixant l'organigramme de l'Agence nationale de la Statistique et de la Démographie (ANSD)

[3] DIALLO M.(2021) Samplics : Python library for survey sampling and estimation [Internet]. Version 0.X. 2023. Disponible à : https ://samplics.github.io/samplics/

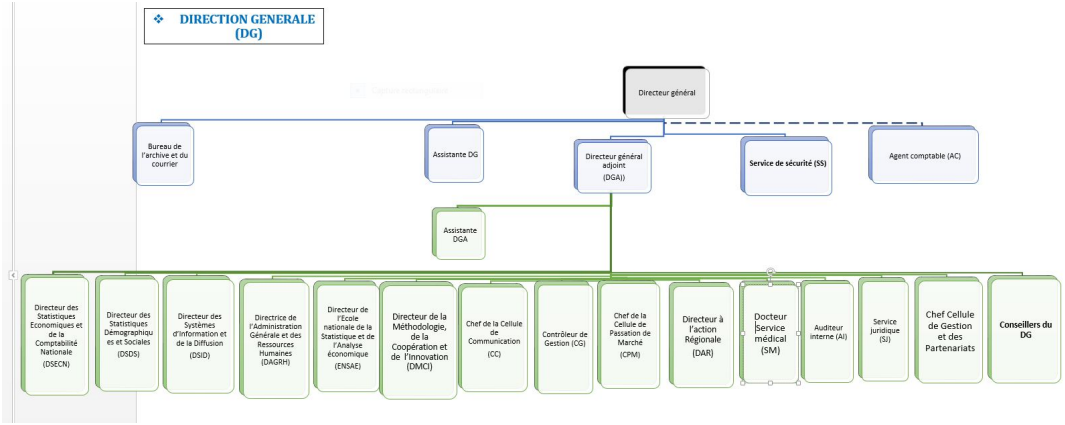
[4] FOFANA S. (2024). Cours Théorie et Pratiques de Sondage. ENSAE-Sénégal

[5] Statistique Canada. (2003). Méthodes et pratiques d'enquête. Ottawa, ON : Statistique Canada.

[6] Streamlit, Inc. Snowflake. (2023).Streamlit : The fastest way to build and share data apps [Internet]. Disponible à : https ://streamlit.io/

ANNEXE

FIGURE 4.1 – *Organigramme de l'ANSD*



Source : *ANSD*

Table des matières

Remerciements ii

Avant-propos iii

Sommaire iv

Liste des figures v

Liste des tableaux vi

Sigles et Acronymes vii

Résumé viii

Abstract ix

Introduction générale 1

1 Présentation de la structure d'accueil 2

1.1 Présentation de l'ANSD . . . 2

1.1.1 Historique et missions de l'ANSD . . . 2

1.1.2 Organisation de l'agence . . . 3

1.2 Présentation de la DMCI . . . 4

1.2.1 Division de la Méthodologie et de l'Innovation (DMI) . . . 5

1.2.2 Division de la Coopération et de la Coordination Statistique (DCC) . . . 5

1.3 Bilan du stage . . . 6

2 Définitions et méthodologie des sondages 7

2.1 Définition et processus du sondage . . . 7

2.1.1 Définition des concepts . . . 7

2.1.2 Processus d'élaboration d'un sondage . . . 9

2.2 Méthodologie . . . 11

2.2.1 Présentation des différentes méthodes de sondage ou d'échantillonnage 11

2.2.2 Sondage aléatoire simple . . . 13

2.2.3 Sondage stratifié . . . 17

3 Présentation de l'application **20**
3.1 Justification de l'application 20
3.1.1 Accessibilité du tirage de l'échantillon 20
3.1.2 Gain de temps et d'efficacité 21
3.1.3 Réduction des erreurs de calcul 21
3.2 Présentation de l'application SamPower 21
3.3 Description des fonctionnalités 21
3.3.1 Etape 1 : Choix de la méthode et de la base de sondage 22
3.3.2 Etape 2 : Choix des paramètres 22
3.3.3 Etape 3 : Téléchargement des résultats 24
3.4 Architecture de l'application 24
3.4.1 Streamlit 24
3.4.2 Samplics 25

4 Cas d'utilisation de SamPower **26**
4.1 Présentation de la base de sondage 26
4.1.1 Echantillonnage avec SamPower 27
4.2 Vérification de la représentativité des échantillons tirés avec samPower . . . 27
4.2.1 Méthodologie 27
4.2.2 Résultats et interprétation 28

Conclusion et recommandations **29**

Bibliographie **xiii**

Annexe **xiv**