République du Sénégal



Agence nationale de la Statistique et de la Démographie



Ecole nationale de la Statistique et de l'Analyse économique Pierre NDIAYE



RAPPORT DE STAGE

CIBLAGE DES MENAGES PAUVRES AU SENEGAL PAR DES ALGORITHMES D'APPRENTISSAGE STATISTIQUE : ANALYSE DES ERREURS DE PREDICTION

Rédigé par :

ONANENA AMANA Jeanne De La Flèche

Elève Ingénieure statisticienne économiste en troisième année de formation du cycle long

Encadreurs :

Mamadou MBODJ

Chef du Bureau de la recherche et de l'innovation

Assana-Richard AYIZOU

Ingénieur statisticien économiste/Consultant à la DMCI

Décembre 2024

DECHARGE

L'Ecole nationale de la Statistique et de l'Analyse économique Pierre NDIAYE (ENSAE) et le Bureau de la Recherche et de l'Innovation (BRI) ne prennent pas position quant aux opinions présentées dans ce rapport. Ces opinions doivent être considérées comme étant celles de l'auteur.

Remerciements

Nous voulons exprimer notre reconnaissance particulière au corps administratif de l'Agence nationale de la Statistique et de la Démographie (ANSD) du Sénégal, ainsi qu'à l'administration de l'école, notamment :

- Dr. Abdou DIOUF, Directeur Général de l'ANSD ;
- Dr Momath CISSE, Directeur Général Adjoint de l'ANSD ;
- M. Idrissa DIAGNE, Directeur de l'ENSAE ;
- M. Fode DIEME, Directeur de la DMCI ;
- M. Mamadou BALDE, Chef de l'unité de formation des ISE à l'ENSAE ;
- M. Moussa DIALLO , Chef de la Division de la Méthodologie et de l'Innovation ;
- Les membres du Bureau de la Recherche et de l'Innovation ;
- Les membres du Bureau des Méthodes et Normes ;

Nous souhaitons également exprimer notre profonde gratitude envers ceux qui ont contribué de différentes manières à l'élaboration de ce document. De ce fait, nous remercions chaleureusement nos encadreurs :

- M. Mamadou MBODJ, Chef du Bureau de La Recherche et de l'Innovation ;
- M. Assana-Richard AYIZOU, Ingénieur statisticien économiste, Consultant au BRI ;

Leurs précieux conseils, leur suivi et leur sens de la rigueur ont été le socle de l'élaboration du présent rapport, et pour cela, nous leur en sommes extrêmement reconnaissants.

Enfin, nous remercions sincèrement nos camarades et amis qui ont fourni des suggestions et des critiques constructives pour l'élaboration de ce rapport. À tous ceux qui ont bien voulu relire ce document, nous vous disons merci.

Avant-propos

L'Ecole nationale de la Statistique et de l'Analyse économique Pierre NDIAYE (ENSAE) est un établissement d'enseignement supérieur rattaché à l'Agence nationale de la Statistique et de la Démographie (ANSD). Elle est membre du Réseau des Écoles de Statistiques Africaines (RESA), avec l'École Nationale de la Statistique et d'Économie Appliquée (ENSEA) d'Abidjan, l'Institut Sous-régional de la Statistique et d'Économie Appliquée (ISSEA) de Yaoundé et l'École nationale d'économie Appliquée et de Management (ENEAM) de Cotonou.

L'école forme des Ingénieurs statisticiens économistes (ISE) en cycles court et long, et des Analystes Statisticiens (AS). Elle forme également des spécialistes en évaluation d'impact à travers son master « Aide à la Décision et Évaluation des Politiques Publiques » (ADEPP), en partenariat avec l'Université Paris Dauphine-PSL et l'Institut de Recherche pour le Développement (IRD).

Les élèves en 2ème année de l'unité de formation ISE Cycle long doivent effectuer un stage de deux mois dans une Institution nationale de Statistique. À l'issue de ce stage, ils doivent rédiger un rapport qui sera soutenu devant un jury sélectionné par l'administration de l'école. L'objectif du stage est de permettre à l'élève de mettre en pratique les connaissances théoriques acquises lors de sa formation, d'avoir un premier contact avec le monde professionnel et de contribuer aux travaux de la structure d'accueil. C'est dans ce cadre que s'inscrit le présent travail, intitulé « **Ciblage des pauvres au Sénégal par des algorithmes d'apprentissage statistique : Analyse des erreurs de prédiction** », réalisé au sein du **BRI (Bureau de la Recherche et de l'Innovation)**. Ce travail permettra de sortir les facteurs explicatifs des erreurs du modèle de prédiction.

Sommaire

Décharge i

Remerciements ii

Avant-propos iii

Sommaire iv

Sigles et abréviations v

Liste des figures vi

Liste des tableaux vii

Résumé 1

Introduction 2

1 Présentation de la structure d'accueil : ANSD 5

2 Cadre conceptuel et source de données 14

3 Présentation et interprétation des résultats de l'analyse bivariée, des tests statistiques et du modèle 26

4 Principaux résultats et recommandations 55

Conclusion 58

Références bibliographiques 59

Annexes I

Table des matières V

Sigles et abréviations

ANSD	:	Agence nationale de la Statistique et de la Démographie
SNDS	:	Stratégie nationale de Développement de la Statistique
DMCI	:	Direction de la Méthodologie, de la Coordination statistique et de l'Innovation
BRI	:	Bureau de la Recherche et de l'Innovation
EHCVM	:	Enquête Harmonisée sur les Conditions de Vie des Ménages
RGPH	:	Recensement Général de la Population et de l'Habitat
IPM	:	Indice de Pauvreté Multidimensionnelle
PMT	:	Proxy Means Tests
PNBSF	:	Programme National de Bourses de Sécurité Familiale

Table des figures

2.1 Présentation de la source de données 21

3.1 Distribution de l'indicateur de pauvreté réel et prédit suivant le mode d'évacuation des ordures ménagères (%) 29
3.2 Distribution de l'indicateur de pauvreté réel et prédit suivant le type sanitaire (%) 32
3.3 Distribution de l'indicateur de pauvreté réel et prédit suivant le type de matériaux de construction des toits (%) 33
3.4 Distribution de l'indicateur de pauvreté réel et prédit suivant le type de logement (%) 34
3.5 Distribution de l'indicateur de pauvreté réel et prédit suivant le mode d'éclairage (%) 35
3.6 Distribution du taux d'emploi du ménage selon le type d'erreur (%) 39
3.7 Distribution du mode d'évacuation des ordures ménagères selon le type d'erreur en milieu rural (%) 40
3.8 Distribution de la taille du ménage selon le type d'erreur 41
3.9 Distribution des sources d'approvisionnement en eau selon le type d'erreur en milieu rural (%) 42
3.10 Distribution du taux de promiscuité selon le type d'erreur 43
3.11 Distribution des sources d'approvisionnement en eau selon le type d'erreur en milieu urbain (%) 44
3.12 Distribution des modes d'évacuation des eaux usées selon le type d'erreur(%) 45

Liste des tableaux

2.1 Variables explicatives de l'algorithme de ciblage 22

3.1 Distribution de l'indicateur de pauvreté réel et prédit suivant la possession d'appareils d'équipement 27
3.2 Distribution de l'indicateur de pauvreté réel et prédit suivant les sources d'approvisionnement en eau (%) 30
3.3 Distribution de l'indicateur de pauvreté réel et prédit suivant le mode d'évacuation des eaux usées (%) 37
3.4 Résultats des tests statistiques en milieu urbain 46
3.5 Résultats des tests statistoques en milieu rural 47
3.6 Précision du modèle multinomial en milieu urbain et rural 49
3.7 Facteurs explicatifs des erreurs du modèle en milieu rural 51
3.8 Facteurs explicatifs des erreurs de prédictions en milieu urbain 53

Résumé

La Direction de la Méthodologie, de la Coordination Statistique et de l'Innovation (DMCI) de l'ANSD a développé un algorithme de ciblage des ménages pauvres en utilisant les données de la deuxième Enquête Harmonisée sur les Conditions de Vie des Ménages (EHCVM II) et appliqué aux données du cinquième Recensement Général de la Population et de l'Habitat (RGPH-5). Bien que cet algorithme présente une précision élevée, il commet des erreurs d'inclusion (ménages non pauvres classés comme pauvres) et d'exclusion (ménages pauvres classés comme non pauvres). Ce document vise à analyser ces erreurs de prédiction et à identifier les facteurs qui les expliquent. Pour ce faire, les variables de pauvreté réelle et prédite ont été croisées avec celles décrivant les conditions de vie des ménages afin de comparer les profils et d'identifier les similitudes et différences entre les groupes. L'analyse repose sur des statistiques descriptives, des tests statistiques (Khi-deux, Fisher exact, Kruskal-Wallis) et un modèle logistique multinomial. Les résultats révèlent que les erreurs sont principalement dues aux similitudes dans les conditions de vie des ménages. Les ménages pauvres classés comme tels partagent des caractéristiques communes avec les ménages non pauvres classés comme pauvres par l'algorithme, tandis que les non pauvres présentent des similitudes avec les ménages pauvres classés comme non pauvres. Les tests statistiques ont mis en évidence des relations significatives entre le type d'erreurs de prédiction et des variables telles que la possession d'équipements (frigo, ventilateur, fer électrique), l'accès aux services de base (source d'eau, type sanitaire, mode d'évacuation des ordures ménagères ménagères and des eaux usées) et la région. Enfin, le modèle multinomial a montré que les facteurs explicatifs communs aux milieux rural et urbain incluent la possession d'équipements et l'accès aux services de base. Toutefois, en milieu rural, les matériaux des murs, le mode d'évacuation des eaux usées et le type de logement sont des facteurs spécifiques, alors qu'en milieu urbain, ce sont la nature du sol, les matériaux des toits, la région et le mode d'éclairage qui influencent les erreurs de classification.

Mots et expressions clés : Pauvreté, apprentissage statistique, Erreur d'inclusion, erreur d'exclusion, tests statistiques, modèle logistique multinomial.

Introduction

Le Sénégal, à l'instar de nombreux pays en développement, fait face à des défis majeurs dans la réduction de la pauvreté et l'amélioration des conditions de vie de sa population. Pour que les politiques publiques de lutte contre la pauvreté soient efficaces, il est essentiel de disposer de mécanismes de ciblage précis permettant d'identifier les ménages les plus vulnérables et de leur fournir une assistance adaptée notamment en leur accordant des bourses de sécurité familiales à travers le PNBSF, les bourses de couverture maladie ainsi qu'une aide aux ménages agricoles vulnérables. L'Agence nationale de la Statistique et de la Démographie (ANSD), en tant qu'institution chargée de la production et de la diffusion des statistiques officielles, joue un rôle clé en élaborant des indicateurs de bien-être destinés à répondre aux besoins des citoyens. Cependant, elle doit constamment relever des défis, notamment en matière d'amélioration de la couverture statistique des indicateurs produits.

Afin de répondre à ces défis, l'ANSD s'appuie sur la Stratégie nationale de Développement de la Statistique (SNDS), un cadre stratégique adopté pour la première fois en 2014, dont l'objectif est de renforcer la fiabilité, l'efficacité et la pertinence du système statistique national au service des politiques publiques. La SNDS vise à coordonner et améliorer la production de données statistiques de qualité pour soutenir la planification, la mise en œuvre et le suivi des politiques de développement économique et social. Dans le cadre de la mise en œuvre de cette stratégie, notamment sa quatrième révision (SNDS IV), l'ANSD a créé en 2023 la Direction de la Méthodologie, de la Coordination statistique et de l'Innovation (DMCI). Cette direction a pour mission d'élaborer et de promouvoir des méthodologies et pratiques statistiques innovantes. Le Bureau de la Recherche et de l'Innovation (BRI), qui en fait partie, a pour mission de développer des approches novatrices pour la construction d'indicateurs et les méthodes de ciblage basées sur des techniques modernes.

En 2024, dans le cadre du Data Innovation Lab, le BRI a lancé un projet visant à cibler les ménages pauvres au Sénégal en utilisant des techniques d'apprentissage statistique,

notamment le Random Forest (forêt aléatoire) et le Gradient Boosting. Des approches similaires basées sur l'utilisation des données satellitaires couplée au modèle du réseau de neurones (Jean et al., 2016), et sur l'application de l'intelligence artificielle aux données de téléphonie mobile (Blumenstock et al., 2015) ont été utilisées dans la littérature pour prédire le niveau de pauvreté. D'autres auteurs comme Grosh et Baker (1995) ont quant à eux utilisé les Proxy Means Tests (PMT), et Carvalho et Souza (2019) ont appliqué un algorithme de forêts aléatoires pour estimer la probabilité qu'un ménage soit pauvre sur la base de ses caractéristiques observées. Un des enjeux majeurs des approches basées sur les données non traditionnelles est de pouvoir garantir la qualité des données pour assurer la fiabilité des résultats. Néanmoins, un défi commun à ces modèles d'apprentissage est de pouvoir minimiser les erreurs de classification (Kidd et Bailey, 2017 ; et Brown et Ravallion, 2020).

Concernant le modèle de ciblage élaboré au niveau du BRI, il combine un algorithme de forêt aléatoire et un algorithme de gradient boosting. Avec ce modèle, un ménage est considéré comme pauvre s'il est identifié comme tel par au moins l'un des deux modèles. Cette approche donne des taux de classification meilleurs que les résultats des deux algorithmes considérés séparément. Toutefois, dans la perspective d'améliorer la qualité du ciblage, il s'avère important de comprendre les facteurs qui expliquent les erreurs de prédictions dans le modèle. La question qui se pose est donc la suivante : **quels sont les facteurs qui expliquent ces erreurs de prédiction dans le modèle final ?**

L'intérêt d'identifier ces facteurs est d'une part de comprendre si certaines des variables prédictives sont fortement liées aux erreurs du modèle, et d'autre part, de distinguer ces facteurs suivant le milieu de résidence. Cette analyse permettra d'identifier des méthodes de traitements adéquats pour améliorer la précision du modèle de ciblage. Ainsi, l'objectif général de ce travail est de déterminer parmi les variables prédictives du modèle de ciblage, les facteurs qui influencent significativement les erreurs de prédictions. Plus spécifiquement, ce travail vise à :

- dresser le profil des ménages suivant l'indicateur de pauvreté réel et l'indicateur de pauvreté prédit ;
- mettre en évidence les ressemblances et les dissemblances entre les ménages bien classés et ceux mal classés par le modèle ;

- déterminer les facteurs explicatifs des erreurs de prédiction.

La méthode d'analyse utilisée à cet effet exploite des statistiques descriptives (tableaux de contingence et graphiques), des tests statistiques et un modèle logistique multinomial. Elle repose sur deux principales hypothèses :

- **Hypothèse 1 :** les ménages classés comme pauvres par erreur (erreurs d'inclusion) partagent les mêmes caractéristiques que les ménages réellement pauvres ;
- **Hypothèse 2 :** les ménages exclus (erreurs d'exclusion) présentent un profil similaire à celui des non-pauvres.

Ce document est structuré en quatre chapitres. Le premier chapitre présente le cadre du stage et la structure d'accueil ainsi que les missions effectuées pendant le stage. Le deuxième chapitre aborde la revue de littérature et la méthodologie adoptée. Il présente quelques travaux sur le ciblage des pauvres effectués dans la littérature et décrit la source de données, les variables utilisées ainsi que l'approche de modélisation. Le troisième chapitre, quant à lui, est consacré à l'analyse descriptive. Il présente les tableaux de contingence et les graphiques réalisés pour dresser le profil des ménages, les tests statistiques qui montrent les ressemblances et les dissemblances des ménages bien classés et mal classés par le modèle de ciblage, et le modèle qui permet d'identifier les facteurs explicatifs des erreurs. Enfin, le quatrième chapitre résume les principaux résultats obtenus et propose des recommandations pour améliorer le ciblage des ménages pauvres.

Chapitre 1

Présentation de la structure d'accueil : ANSD

...

Le stage qui a duré deux mois a été effectué à l'Agence nationale de la Statistique et de la Démographie, à la Direction de la Méthodologie, de la Coordination statistique et de l'Innovation plus précisément au Bureau de la Recherche et de l'Innovation. Ce chapitre se concentre sur la présentation de cette structure, à travers ses missions, les différents services centraux et ses directions.

1.1 Historique et missions

1.1.1 Historique

L'Agence nationale de la Statistique et de la Démographie (ANSD) est une institution publique au Sénégal, dotée de la personnalité juridique et d'une autonomie de gestion. Elle est placée sous la tutelle du ministère chargé de la statistique et fonctionne sous la gouvernance d'un Conseil de Surveillance. Ce conseil est composé de représentants de la Primature, du Ministère de l'Économie, des Finances et du Plan (MEFP), de la Banque Centrale, des organisations patronales, des syndicats des travailleurs, ainsi que des centres de recherche universitaire. La Direction générale, dirigée par un Directeur général et un Directeur général adjoint, tous deux nommés par décret, constitue l'organe de direction exécutive de l'ANSD.

1.1.2 Missions

L'ANSD a pour mission principale de garantir la cohésion technique des activités du Système Statistique National (SSN) et de veiller à la production et à la diffusion des données

statistiques. Ces données servent de support essentiel aux décisions du gouvernement, des administrations publiques, du secteur privé, ainsi que des partenaires au développement.

Les missions de l'ANSD incluent :

- l'élaboration et la mise en œuvre des programmes pluriannuels et annuels de statistique ;
- l'application des méthodes, concepts, normes, classifications et nomenclatures validés par le comité technique des programmes statistiques ;
- la préparation des dossiers pour les réunions du conseil national de la statistique et du comité technique des programmes statistiques ;
- l'organisation et le secrétariat des réunions du conseil national de la statistique et du comité technique des programmes statistiques, y compris de ses sous-comités sectoriels ;
- la réalisation d'enquêtes à couverture nationale, comme les recensements généraux de la population et ceux des entreprises ;
- la production des comptes nationaux ;
- le suivi de la conjoncture et la prévision économiques en lien avec le service chargé de la prévision économique ;
- la gestion des fichiers des entreprises et des localités ;
- l'élaboration des indicateurs économiques, sociaux et démographiques ;
- la centralisation et la diffusion des données statistiques produites par l'ensemble du SSN ;
- le développement des sciences statistiques et de la recherche économique appliquée dans son domaine de compétence ;
- la formation du personnel spécialisé pour le fonctionnement du système national d'information statistique, notamment par l'organisation de cycles de formation au sein d'une école à vocation régionale ou sous-régionale intégrée à l'agence.

L'ANSD est également responsable du suivi de la coopération technique internationale en matière statistique. À ce titre, elle représente le Sénégal dans les réunions

sous-régionales, régionales et internationales portant sur les questions statistiques et suit les activités des organisations internationales dans ce domaine.

1.2 Les services centraux

L'ANSD compte huit (8) directions qui sont sous l'autorité du Directeur général adjoint :

- la Direction des Statistiques économiques et de la Comptabilité nationale (DSECN) ;
- la Direction des Statistiques démographiques et sociales (DSDS) ;
- la Direction de la Méthodologie, de la Coordination statistique et de l'Innovation (DMCI) ;
- la Direction des Systèmes d'Information et de la Diffusion (DSID) ;
- la Direction de l'Administration générale et des Ressources humaines (DAGRH) ;
- la Direction de l'Ecole nationale de la Statistique et de l'Analyse économique Pierre NDIAYE (ENSAE) ;
- la Direction à l'Action Régionale (DAR) ;
- l'Agence comptable (AC).

Sur le plan hiérarchique, l'Agent comptable est rattaché au Directeur général.

1.2.1 Direction des Statistiques Économiques et de la Comptabilité Nationale (DSECN)

La DSECN est responsable de l'élaboration des statistiques économiques globales et de la production des comptes nationaux. Elle mène également des études et recherches spécifiques. Elle est organisée en trois divisions :

- Division des Statistiques Économiques : Chargée de la Banque de Données Économiques et Financières (BDEF), du suivi de la démographie des entreprises, et de la conception des systèmes d'information statistique des entreprises.
- Division de la Comptabilité Nationale : Produit et analyse les comptes nationaux

en synthétisant les statistiques et indicateurs des autres unités de l'ANSD et des organismes extérieurs. Elle élabore également les comptes nationaux sectoriels et satellites.

- Division des Statistiques Conjoncturelles : Conçoit et réalise des enquêtes de conjoncture auprès des entreprises et élabore les statistiques du commerce extérieur et des indicateurs conjoncturels.

1.2.2 Direction des Statistiques Démographiques et Sociales (DSDS)

La DSDS est chargée de la conception, de l'exécution et de l'analyse des enquêtes et recensements démographiques et socio-économiques auprès des ménages. Elle centralise et traite les fichiers d'état civil reçus au niveau régional et établit des statistiques socio-démographiques pour le suivi des programmes de développement. Elle comprend trois divisions :

- Division du Recensement et des Statistiques Démographiques (DRSD)
- Division des Statistiques Sociales et du Suivi de la Pauvreté (DSSSP)
- Division de la Cartographie et de l'Échantillonnage (DCE)

1.2.3 Direction des Systèmes d'Information et de la Diffusion (DSID)

La DSID assure la gestion des systèmes d'information de l'ANSD et supervise la diffusion de ses produits. Elle est organisée en deux divisions :

- Division de la Diffusion (DD)
- Division de l'Informatique (DI)

1.2.4 Direction de l'Administration Générale et des Ressources Humaines (DAGRH)

La DAGRH gère le personnel et les compétences, assure la sécurité, l'approvisionnement, et la logistique de l'ANSD. Elle coordonne la préparation du budget et supervise la gestion des stocks. Elle comprend deux divisions :

- Division des Ressources Humaines (DRH)

- Division de l'Administration Générale et des Finances (DAGF)

1.2.5 Direction de l'École Nationale de la Statistique et de l'Analyse Économique Pierre Ndiaye (ENSAE)

L'ENSAE, rattachée à l'ANSD, est chargée de la formation permanente des statisticiens de l'agence et du SSN. Elle veille à la bonne application des enseignements en lien avec le Conseil de Surveillance de l'ANSD. Elle est composée de :

- Direction des Études et des Stages
- Unité de Recherche
- Secrétariat Administratif

1.2.6 Agence Comptable (AC)

L'AC est responsable de la gestion des recettes et dépenses, ainsi que de la conservation des patrimoines financiers et non financiers. Elle est dirigée par un Agent comptable nommé par le ministre des Finances. Elle comprend :

- Division de la Comptabilité Générale, de la Trésorerie et du Recouvrement
- Division des Dépenses

1.2.7 La Direction de la Méthodologie, de la Coordination statistique et de l'Innovation (DMCI)

La DMCI est responsable de l'élaboration et de la vulgarisation des méthodologies et des bonnes pratiques en matière de statistique. Son rôle principal est d'harmoniser les concepts, nomenclatures, et classifications utilisées à l'ANSD et au sein de tout le Système statistique national (SSN). Elle met également en place un cadre national d'assurance qualité et assure une veille technologique active tout en promouvant la recherche et l'innovation. En plus de ces fonctions, la DMCI coordonne et programme les activités statistiques du SSN et supervise la coopération internationale de l'ANSD. Elle sert d'interlocuteur entre l'ANSD et les autres structures membres du SSN et appuie le Directeur général dans la préparation des dossiers pour le Conseil national de la Statistique (CNS) et le Comité

technique des Programmes statistiques (CTPS). La DMCI veille également à la qualité des résultats produits et au maintien d'un niveau élevé de maîtrise des techniques statistiques. La DMCI est structurée en deux divisions :

- Division de la Méthodologie et de l'Innovation (DMI)

Cette division est chargée de l'élaboration des recueils de méthodologies, de nomenclatures, et de classifications, ainsi que de la mise en place d'un dispositif d'assurance qualité des données. Elle est également responsable de la promotion de la recherche et de l'innovation, tout en assurant une veille technologique. La DMI se compose de deux bureaux :

- Bureau des Méthodes et Normes (BMN) : Responsable de l'élaboration des recueils méthodologiques et de l'opérationnalisation du cadre national d'assurance qualité. Il coordonne également l'harmonisation des méthodologies au niveau national et international, ainsi que la délivrance des visas statistiques.
- Bureau de la Recherche et de l'Innovation (BRI) : Ce bureau assure la veille technologique et la promotion de la recherche et de l'innovation, en coordonnant la réalisation d'études et d'analyses approfondies en collaboration avec les services compétents du SSN.
- Division de la Coopération et de la Coordination statistique (DCC)

Cette division assure le suivi et l'évaluation des Stratégies nationales de Développement de la Statistique (SNDS) et des Plans stratégiques de Développement (PSD). Elle administre la plateforme PTA, réalise la cartographie du SSN, organise les réunions du CNS et du CTPS, et anime le portail web du SSN. De plus, elle coordonne le renforcement des capacités au sein du SSN en collaboration avec l'ENSAE et d'autres structures. La DCC est également en charge de la coopération internationale. Elle se compose de deux bureaux :

- Bureau de la Coordination Statistique (BCS) : Coordonne les activités statistiques du SSN et de l'ANSD, administre la plateforme PTA, et assure la satisfaction des utilisateurs du SSN par le biais de diverses enquêtes et initiatives.
- Bureau de la Coopération Internationale (BCI) : Interlocuteur principal pour la coopération internationale, ce bureau veille au suivi des indicateurs ODD et coordonne les projets en lien avec ces objectifs. Il s'occupe également de la Norme spéciale de Diffusion des données (NSDD) et d'autres initiatives internationales.

- Cellule de gestion des partenariats (CGP)

La CGP coordonne la mise en œuvre et le suivi des conventions de partenariats et des prestations à frais recouvrables. Elle s'occupe de promouvoir les produits et services de l'ANSD auprès des clients potentiels. La CGP comprend deux unités :

- Unité de la gestion des partenariats (UGP) : Chargée de l'exécution des prestations à frais recouvrables et de l'élaboration des offres techniques et financières. Elle accompagne également l'Unité de la promotion et du développement des partenariats (UPDP) dans les négociations et la mise en œuvre des travaux.
- Unité de la promotion et du développement des partenariats (UPDP) : Responsabilité de développer le portefeuille clientèle et de commercialiser les produits de l'ANSD, en proposant des conventions de partenariat adaptées aux besoins des différents segments du marché.

1.2.8 Direction à l'Action Régionale (DAR)

La Direction à l'Action Régionale (DAR) représente l'ANSD au niveau régional. A travers les Services régionaux de la Statistique et de la Démographie (SRSD) qui lui sont rattachés, la DAR est chargée :

- de la gestion du personnel, du matériel et des moyens financiers mis à la disposition des Services ;
- d'assurer la coordination et l'animation du système statistique régional ;
- de piloter les opérations de collecte, de procéder au traitement et à l'analyse des données au niveau régional et local ;
- de coordonner et gérer, au niveau décentralisé, l'ensemble des enquêtes conçues par les directions techniques de l'ANSD ;
- d'assurer la collecte et le traitement des données auprès des services décentralisés et déconcentrés de l'État ;
- d'élaborer les documents sur la situation économique et sociale de la région ;
- d'appuyer l'exécutif régional (autorités locales), les structures déconcentrées et les ONG, dans la mise en œuvre des projets et programmes de développement ;

- de mener des études spécifiques (monographies, notes de conjoncture, etc.) nécessaires à la connaissance de la situation économique, démographique et sociale de la région ;
- de diffuser des statistiques et études nationales et régionales dans la région ;
- d'assister les autres composantes du Système statistique national dans leurs actions au niveau de la région ;
- d'assurer la coordination de l'élaboration et l'actualisation du Programme national d'activités statistiques, de ses plans annuels d'action et de toute stratégie de développement de la statistique ;
- de contribuer à la préparation du rapport annuel d'exécution du Programme national d'activités statistiques et au suivi de la mise en œuvre des plans d'action ;
- de contribuer au renforcement des capacités en matière de statistiques des services sectoriels régionaux.

1.3 Missions pendant le stage

Le stage s'est déroulé à l'ANSD du lundi 5 août au vendredi 4 octobre 2024, au sein de la Direction de la Méthodologie, de la Coordination Statistique et de l'Innovation (DMCI), plus précisément au Bureau de la Recherche et de l'Innovation (BRI). Notre objectif principal était de contribuer au projet de ciblage des ménages pauvres au Sénégal. Les principales missions réalisées durant cette période ont été de :

- Comprendre les algorithmes de ciblage existants avant le début de notre stage.
- Analyser les erreurs d'inclusion et d'exclusion de l'algorithme en calculant les taux d'erreur et en effectuant des statistiques descriptives.
- Rédiger un rapport détaillant l'ensemble des travaux accomplis durant le stage.
- Réaliser une classification des ménages à l'aide d'algorithmes d'apprentissage statistique. À cet effet, un algorithme de classification basé sur la méthode des k-means a été développé pour distinguer les ménages pauvres des non pauvres.

Par ailleurs, nous avons participé activement à la vie professionnelle du bureau, en

assistant aux réunions de bureau et aux séances de travail sur des projets de la direction notamment, la correction des questionnaires d'enquête, la planification d'une enquête de vérification du modèle de ciblage. Ce stage nous a offert une occasion d'acquérir une expérience pratique, d'appliquer nos connaissances théoriques à des problématiques concrètes et de contribuer à un projet d'envergure nationale notamment, la classification des ménages en utilisant des algorithmes d'apprentissage statistique. Nous avons ainsi renforcé nos compétences en analyse statistique et en apprentissage statistique, tout en développant une meilleure compréhension des enjeux liés au ciblage des ménages pauvres au Sénégal.

Chapitre 2

Cadre conceptuel et source de données

...

Ce chapitre expose les recherches précédemment menées sur le ciblage des ménages pauvres, en mettant en avant l'utilisation des méthodes traditionnelles ainsi que des techniques de machine learning. Il décrit également la source des données utilisées dans le cadre de cette étude, tout en détaillant la méthodologie adoptée pour la réalisation du travail.

2.1 Revue de littérature

2.1.1 Les méthodes traditionnelles pour la prédiction de la pauvreté

Les études sur la pauvreté reposent sur des contributions fondamentales qui ont façonné la compréhension et la mesure de ce phénomène. L'ouvrage de Rowntree (1901), *Poverty : A Study of Town Life*, a marqué un tournant en proposant une méthode empirique basée sur des enquêtes directes pour définir un seuil de pauvreté absolue. Ce seuil était calculé en tenant compte des besoins essentiels en nourriture, logement et vêtements, et permettait de distinguer les ménages vivant en dessous du niveau de subsistance. Rowntree a observé que près de 28% des ménages étudiés vivaient en dessous de ce seuil, soulignant l'ampleur du problème dans les zones urbaines au Royaume-Uni. Cette méthode, bien qu'innovante pour son époque, se concentrait exclusivement sur les aspects monétaires de la pauvreté.

Amartya Sen (1985), dans son ouvrage *Commodities and Capabilities*, a quant à lui introduit une perspective plus large en proposant l'approche des capacités. Il a souligné que la pauvreté n'est pas seulement un manque de revenu, mais une privation des capacités fondamentales qui permettent aux individus de mener une vie digne. Pour mesurer ces

privations, Sen a recommandé l'utilisation d'indicateurs multidimensionnels, qui prennent en compte des aspects tels que la santé, l'éducation et les conditions de vie. Cette vision a influencé des mesures comme l'Indice de Pauvreté Multidimensionnelle (IPM) d'Alkire et Foster (2011). Pour ce qui est de l'IPM, il repose sur une méthode de pondération et une règle de coupure : un ménage est considéré comme pauvre si la somme pondérée des privations dépasse un seuil fixé, souvent 33%. L'application de l'IPM a révélé, par exemple, que dans plusieurs pays en développement, plus de 40% des ménages sont pauvres multi dimensionnellement, même si leur pauvreté monétaire est moins marquée.

L'introduction des modèles de régression pour estimer la probabilité qu'un ménage soit pauvre a marqué une avancée majeure dans le ciblage des ménages pauvres. Coady et al. (2004), dans leur ouvrage *Targeting of Transfers in Developing Countries : Review of Lessons and Experience*, ont démontré que les modèles économétriques, en utilisant des variables telles que la taille du ménage ou le niveau d'éducation, améliorent significativement la précision du ciblage par rapport aux approches traditionnelles. Leur méthode repose sur la modélisation de données d'enquête et l'application de techniques statistiques sophistiquées pour affiner les prédictions.

Traditionnellement, les méthodes de ciblage reposaient sur des enquêtes sur les revenus et des systèmes de scoring basés sur des indicateurs socio-économiques. Bigman et Fofack (2000), dans leur article *Geographical Targeting for Poverty Alleviation*, ont proposé un ciblage géographique utilisant des données agrégées pour diriger les ressources vers les régions les plus pauvres. Cette approche réduit les erreurs d'exclusion de 15% par rapport aux ciblages individuels, mais elle devient moins efficace lorsque la pauvreté est inégalement répartie au sein des régions. Grosh et Baker (1995), dans *Proxy Means Tests for Targeting Social Programs*, ont introduit les Proxy Means Tests (PMT), qui reposent sur des modèles économétriques pour estimer la pauvreté. La formule générale du PMT est la suivante :

$$\hat{Y}_i = \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n$$

Où $\widehat{Y}_i$ est le niveau de revenu prédit pour le ménage i, $X_1, X_2, \ldots, X_n$ sont les variables explicatives (ex. : taille du ménage, niveau d'éducation, etc.), et β représente les coefficients

estimés. Les ménages sont classés comme pauvres si $\widehat{Y}_i$ est inférieur à un seuil de pauvreté défini. Selon Grosh et Baker, les simulations menées en Amérique latine montrent que les PMT peuvent réduire les erreurs d'inclusion de 10 à 15%, à condition de disposer de données de qualité. Ils recommandent également de combiner les PMT avec des enquêtes participatives pour en améliorer la précision.

2.1.2 Introduction du machine learning dans le ciblage des ménages pauvres

Avec l'avènement des données massives, les méthodes de machine learning (ML) ont émergé comme une alternative prometteuse pour le ciblage des ménages pauvres. Ces méthodes permettent de capter des relations complexes entre les variables socio-économiques, souvent non détectables par les approches traditionnelles. Les algorithmes de ML peuvent être supervisés (régression logistique, forêts aléatoires) ou non supervisés (clustering). La fonction de perte d'un modèle de régression logistique, couramment utilisée, est définie par :

$$L(\theta) = -\sum_{i=1}^{n} \left(y_i \log\left(h_\theta(x_i)\right) + (1 - y_i) \log\left(1 - h_\theta(x_i)\right)\right)$$

Où $h_\theta(x_i)$ représente la probabilité prédite qu'un ménage i soit pauvre.

L' étude *Predicting poverty and wealth from mobile phone metadata* de Blumenstock et al. (2015) a appliqué des techniques de ML pour prédire la pauvreté à partir de métadonnées de télécommunications au Rwanda. En utilisant des modèles comme la régression logistique et les forêts aléatoires, ils ont montré que des variables telles que la fréquence des appels et les schémas de recharge téléphonique sont de bons prédicteurs de la pauvreté. Le modèle final a atteint une précision de 70% et un taux de rappel de 65%. Cependant, les chercheurs soulignent que cette approche dépend de la qualité des données téléphoniques, qui peuvent exclure les ménages les plus démunis sans accès à un téléphone. Une autre limite relevée est l'absence de mesures directes de la consommation, rendant les prédictions moins fiables pour les ménages marginalisés.

De manière similaire, Jean et al. (2016) dans leur étude *Combining satellite imagery and machine learning to predict poverty* ont utilisé des images satellitaires pour estimer la

pauvreté en Afrique subsaharienne. Grâce à un réseau neuronal convolutif (CNN), ils ont pu prédire les niveaux de pauvreté en se basant sur la luminosité nocturne et la densité des infrastructures. Les résultats ont révélé une corrélation significative (coefficient de Pearson de 0,75) entre les prédictions du modèle et les données d'enquêtes traditionnelles. Les prédictions de pauvreté basées sur les images satellitaires ont permis de réduire les erreurs d'exclusion de 15% par rapport aux méthodes traditionnelles. Toutefois, les auteurs mentionnent que l'interprétation des résultats reste un défi en raison de la complexité des algorithmes et de la sensibilité aux variations locales non capturées par les images.

Dans une autre étude *Targeting accuracy in poverty alleviation programs using machine learning*, Nie, Sousa-Poza et Xue (2021) ont comparé plusieurs algorithmes de classification supervisée, y compris les machines à vecteurs de support (SVM) et les forêts aléatoires, pour cibler les ménages pauvres en Chine. Les forêts aléatoires ont offert la meilleure performance, avec une réduction notable des erreurs d'exclusion (réduction de 12% par rapport aux modèles traditionnels). La précision globale du modèle SVM était de 78%, contre 83% pour les forêts aléatoires. Toutefois, l'une des principales limites relevées est la nécessité de vastes ensembles de données pour l'entraînement, ce qui n'est pas toujours disponible dans les pays en développement.

Engstrom et al. (2017) dans leur étude *Poverty from space : Using high-resolution satellite imagery for estimating economic well-being* ont également exploré l'utilisation des images satellitaires couplées à des techniques de deep learning pour cartographier la pauvreté. Leur approche a montré une précision de 80% dans l'identification des zones de pauvreté extrême, en particulier dans les régions où les enquêtes économiques traditionnelles sont rares. Les résultats indiquent que les régions avec une faible luminosité nocturne et une faible densité infrastructurelle ont un risque de pauvreté 2,5 fois supérieur à celles avec des infrastructures développées. Ils mettent en garde contre les biais potentiels liés à l'interprétation automatique des images, surtout en présence de variations culturelles ou contextuelles qui peuvent ne pas être capturées correctement par les algorithmes de deep learning.

2.1.2.1 Analyse des erreurs d'inclusion et d'exclusion

Kidd et Bailey (2017) ont mené une étude approfondie dans *The effectiveness of social protection targeting* sur les erreurs d'inclusion et d'exclusion dans les systèmes de transfert

monétaire en Afrique subsaharienne. Leur analyse, basée sur des données provenant de plusieurs programmes sociaux nationaux, a mis en évidence que les erreurs d'exclusion étaient particulièrement fréquentes. Ces erreurs sont souvent dues à la sous-déclaration des revenus par les ménages pauvres ou à l'application de critères de ciblage inappropriés, qui ne tiennent pas suffisamment compte des dynamiques locales de pauvreté. Ils ont également noté que l'utilisation de seuils fixes pour déterminer l'éligibilité des ménages, sans ajustement en fonction du contexte socio-économique, accentuait ces erreurs. Les auteurs recommandent une révision régulière des seuils de pauvreté et une meilleure collecte des données pour réduire ces erreurs.

De leur côté, Brown et Ravallion (2020) ont analysé dans *Reassessing the targeting of social assistance using machine learning*, les erreurs de classification dans les modèles de machine learning (ML) appliqués aux programmes sociaux. Leur étude, réalisée sur des programmes de transfert conditionnel en Amérique latine, a révélé que les biais de sélection des données constituaient la principale source d'erreur. Par exemple, les modèles basés sur des données historiques peuvent ne pas refléter les changements récents dans les conditions de vie des ménages. Ils ont également identifié que les erreurs d'inclusion (ciblage de ménages non pauvres) étaient souvent dues à la sur-représentation de certains groupes sociaux dans les échantillons d'entraînement des modèles. Pour améliorer la précision, ils suggèrent une combinaison de techniques de validation croisée et d'échantillonnage représentatif.

L'étude *Random Forest analysis in Brazilian social programs* de Carvalho et Souza (2019) a appliqué l'algorithme des forêts aléatoires pour évaluer les erreurs d'inclusion et d'exclusion dans un programme social au Brésil. Cette méthode, qui repose sur la construction d'un ensemble d'arbres de décision, vise à améliorer la précision des prédictions. Les critères de décision se basent sur la réduction de l'impureté de Gini pour chaque nœud, en sélectionnant les variables qui maximisent la réduction de l'entropie au sein des groupes cibles. Les résultats ont montré que l'éducation et l'accès aux services sociaux de base étaient les principaux déterminants des erreurs d'inclusion, avec une précision de 82% dans l'identification correcte des ménages pauvres. Toutefois, les auteurs soulignent que la performance des modèles dépend fortement de la qualité des données et de leur capacité à capter des variables non observées, notamment des indicateurs informels de revenus. Une des limites principales est l'exclusion des ménages sans antécédents de

données structurées, ce qui peut biaiser les résultats en faveur des ménages urbains mieux documentés.

Dans une approche similaire, Golan et al. (2020), dans *Sensitivity Metrics in Targeting Accuracy* ont développé une métrique de sensibilité pour quantifier les erreurs dans les modèles de ciblage. Leur méthodologie repose sur l'évaluation comparative des erreurs d'inclusion (faux positifs) et d'exclusion (faux négatifs) par rapport à un seuil de décision basé sur la distribution des scores prédictifs. Ils ont démontré que même une variation de 5% dans la précision des données d'entrée peut entraîner des erreurs de classification importantes, réduisant l'efficacité du ciblage. Leur analyse a également montré que les erreurs d'exclusion étaient souvent dues à une sous-déclaration des actifs des ménages, ce qui biaise le modèle vers une surestimation de la pauvreté dans certains segments de population.

2.1.2.2 Modèles multinomiaux pour l'analyse des erreurs de prédiction

L'étude de Carvalho et al. *Multinomial Logit Analysis of Social Program Errors* de 2019 sur le programme Bolsa Família a appliqué un modèle logit multinomial pour analyser les erreurs d'inclusion et d'exclusion. Le modèle a identifié que la taille du ménage et le niveau d'éducation des chefs de ménage étaient des variables significatives. Par exemple, un ménage de grande taille avait 1,5 fois plus de chance d'être inclus que les ménages plus petits. De même, les ménages dirigés par des individus ayant un niveau d'éducation bas présentaient un risque 20% plus élevé d'être exclus. Les chercheurs ont également démontré que les ménages urbains étaient plus susceptibles d'être mal classifiés par rapport aux ménages ruraux. La limite principale de cette étude réside dans la qualité des données déclaratives, qui peut introduire un biais systématique dans les résultats obtenus.

De leur côté, Agüero et al. (2018) ont mené une analyse similaire dans *Evaluation of Targeting Errors in Social Assistance Programs in Peru* au Pérou pour évaluer les déterminants des erreurs dans les programmes sociaux. Leur étude a révélé que le statut d'emploi du chef de ménage influençait significativement les erreurs d'exclusion : les ménages dirigés par une personne employée de façon informelle avaient 2,3 fois plus de chances d'être exclus à tort du programme que ceux avec un emploi formel. Leur modèle a également souligné que la localisation géographique (zones rurales versus urbaines) jouait un rôle significatif. Toutefois, l'étude a noté des limites liées à la variabilité régionale, suggérant

que des critères de ciblage uniformes ne conviennent pas toujours aux contextes locaux spécifiques.

Ces études démontrent que les critères de décision incluent des facteurs sociodémographiques et économiques, tels que la taille du ménage, l'éducation, et le statut d'emploi, qui influencent différemment chaque type d'erreur. L'intégration de ces résultats permettrait d'améliorer les politiques de ciblage des ménages pauvres en ajustant les paramètres en fonction des contextes locaux.

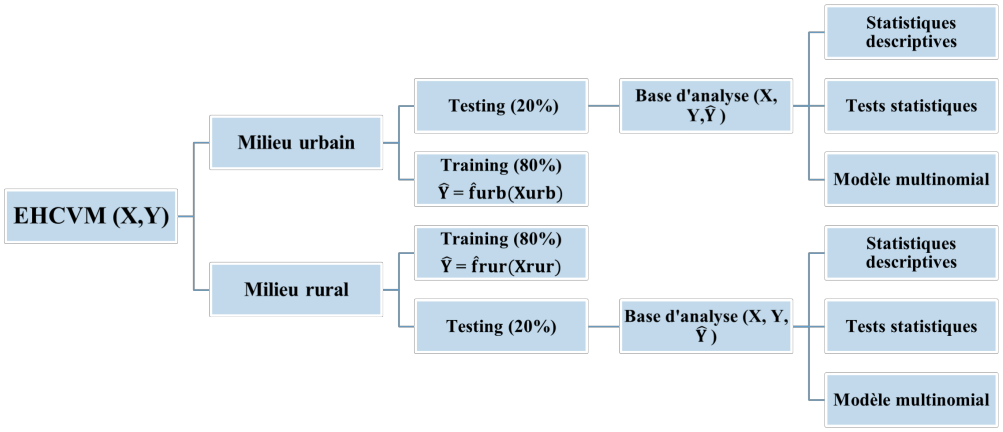
Cette revue de littérature met en lumière l'évolution des méthodes de ciblage de la pauvreté, passant des approches traditionnelles aux techniques avancées de machine learning. Si les modèles traditionnels restent pertinents, les approches modernes offrent des gains de précision significatifs, tout en introduisant de nouveaux défis liés à la qualité des données et aux erreurs de classification. Une combinaison judicieuse des deux approches pourrait maximiser l'efficacité des programmes de lutte contre la pauvreté.

2.2 Méthodologie

2.2.1 Source de données

Les données exploitées dans ce travail proviennent de la deuxième Enquête Harmonisée sur les Conditions de Vie des Ménages (EHCVM-II) réalisée au Sénégal entre 2021 et 2022. A l'issue de cette enquête un indicateur de pauvreté monétaire basé sur les dépenses du ménage a été construit et calculé pour chacun des ménages enquêtés. L'algorithme de ciblage des ménages pauvres a été développé en utilisant les données de cette enquête. Cet algorithme prend en compte deux modèles d'apprentissage supervisé qui prédisent l'indicateur de pauvreté monétaire pour chaque ménage. Ensuite, les résultats des prédictions sont agrégés pour obtenir la prédiction finale dans laquelle un ménage est considéré comme pauvre s'il est prédit comme tel par au moins l'un des modèles. L'algorithme de ciblage a été implémenté suivant le milieu de résidence pour prendre en compte les spécificités du milieu urbain et du milieu rural. Le résumé graphique de la construction du modèle est présenté ci-dessous.

FIGURE 2.1 – Présentation de la source de données



Source : EHCVM 2022, calculs de l'auteur

Comme le montre la figure ci-dessus, les données utilisées pour tester le modèle de ciblage sont celles qui ont été utilisées dans le cadre de cette analyse. Le X représente les variables prédictives, le Y l'indicateur de pauvreté réel et le Y chapeau l'indicateur de pauvreté prédit. Ainsi, pour chaque sous-base, les données comprennent l'indicateur réel de pauvreté, l'indicateur prédit ainsi que les variables explicatives utilisées dans les modèles. La base de données relative au milieu rural contient 36 variables, dont 34 issues de la modélisation et 2 construites (la taille du ménage et le type d'erreur), pour un total de 639 observations. De manière similaire, la base pour le milieu urbain comprend également 36 variables (incluant les deux variables construites) et totalise 781 observations.

2.2.2 Présentation des variables

Les bases de données finales, base rurale et base urbaine, contiennent 36 variables. Parmi elles, on trouve 4 variables quantitatives et 20 variables qualitatives qui sont résumées dans le tableau suivant.

TABLEAU 2.1 – Variables explicatives de l'algorithme de ciblage

Catégories des variables	Libellés des variables
Variables démographiques	Sexe
	Age du chef du ménage
	Taux d'emploi dans le ménage
	Taille du ménage
Variables de possession (biens durables)	Frigo
	Voiture
	Fer à charbon
	Bonbonne de gaz
	Ordinateur
	Fer électrique
	Ventilateur
Variables liées aux conditions de vie	Nature toit
	Partage sanitaire
	Type sanitaire
	Nature du sol
	Nature du mur
	Statut d'occupation
	Type de logement
	Région
	Taux de promiscuité
Variables d'accès	Mode d'éclairage
	Source d'eau
	Mode d'évacuation des ordures ménagères
	Mode d'évacuation des eaux usées

Source : EHCVM 2022, calculs de l'auteur

La base de données fournit le logarithme de la taille du ménage donc la variable taille du ménage a été construite en prenant l'exponentielle de la variable logarithme de la variable taille du ménage. Quant à la variable type d'erreur, qui est l'objet de l'analyse

dans ce travail, elle a été élaborée en croisant la variable de pauvreté initiale (pauvre (1), non pauvre (0)) avec la variable de pauvreté prédite (1, 0). Cette variable comprend quatre catégories : pauvre (ménage pauvre (1) prédit comme pauvre (1)), non pauvre (ménage non pauvre (0) prédit comme non pauvre (0)), exclus (ménage pauvre (1) prédit comme non pauvre (0)) et inclus (ménage non pauvre(0) prédit comme pauvre (1)) qu'on pourrait classer en deux grands groupes. Les biens prédits et les erreurs.

2.2.3 Méthode d'analyse

2.2.3.1 Analyse descriptive et exploratoire

Pour analyser les erreurs de prédiction du modèle final, des statistiques descriptives seront réalisées. Elles permettront de comparer le profil des ménages pauvres réels à celui des ménages pauvres prédits. Des tests statistiques seront utilisés, tels que le test du chi-deux, le test exact de Fisher et le test de Kruskal-Wallis, afin d'évaluer les relations entre les variables explicatives et la variable type d'erreur et ainsi valider ou infirmer les résultats des statistiques descriptives. Le test du chi-deux est appliqué pour évaluer l'indépendance entre deux variables qualitatives. Lorsque les effectifs sont faibles on privilégiera le test de Fisher exact. Le test de Kruskal-Wallis, quant à lui, est un test non paramétrique utilisé pour comparer la distribution d'une variable quantitative entre plusieurs groupes lorsque l'hypothèse de normalité n'est pas respectée par la variable. Ces tests permettent de rejeter ou non l'indépendance entre certaines variables et l'erreur de prédiction. Les variables choisies pour effectuer les tests sont celles que nous considérons comme ayant une influence sur les erreurs du modèle. Pour tous les tests effectués, l'hypothèse nulle suggère qu'il n'y a pas de relation significative entre les variables explicatives et le type d'erreur. Pour valider cette hypothèse, nous allons nous baser sur la p-value supérieure à 0.05 et pour l'infirmer, nous allons nous baser sur une p-value inférieure à 0.05.

2.2.3.2 Modélisation

Un modèle logistique multinomial sera estimé pour ressortir les facteurs expliquant au mieux le type d'erreur. Ce modèle est une généralisation de la régression logistique binaire pour des situations où la variable dépendante est catégorielle avec J catégories ou classes (J>2). Dans notre cas, J vaut 4.

2.2.3.3 Spécification du modèle logistique multinomial

Supposons que Y soit la variable dépendante, prenant J modalités, notées $\{1, 2, \ldots, J\}$. Soit $X = (X_1, X_2, \ldots, X_k)$ un vecteur de k variables explicatives. Le modèle logistique multinomial consiste à estimer la probabilité conditionnelle d'appartenance à chaque catégorie j, étant donnée les valeurs des variables explicatives. Sa formule mathématique est donnée par :

$$P(Y = j \mid X = x) = \frac{e^{\beta_{j0} + \beta_{j1} X_1 + \cdots + \beta_{jk} X_k}}{1 + \sum_{l=1}^{J-1} e^{\beta_{l0} + \beta_{l1} X_1 + \cdots + \beta_{lk} X_k}}$$

pour $j = 1, 2, \ldots, J-1$. P est la probabilité que Y prenne la valeur j étant donnée X.

Pour la dernière catégorie J (qui est prise comme catégorie de référence), la probabilité est donnée par :

$$P(Y = J \mid X = x) = \frac{1}{1 + \sum_{l=1}^{J-1} e^{\beta_{l0} + \beta_{l1} X_1 + \cdots + \beta_{lk} X_k}}$$

Dans le modèle logistique multinomial, les coefficients β_{ji} représentent l'effet de la variable explicative X_i sur le log-rapport de probabilité (log-odds) entre la catégorie j et la catégorie de référence J :

$$\log\left(\frac{P(Y = j \mid X = x)}{P(Y = J \mid X = x)}\right) = \beta_{j0} + \beta_{j1} X_1 + \cdots + \beta_{jk} X_k$$

Chaque coefficient β_{ji} indique comment une unité de changement dans X_i affecte le log-rapport de probabilité d'appartenance à la catégorie j par rapport à la catégorie de référence J.

L'interprétation des résultats du modèle logistique multinomial repose sur l'analyse des effets des variables explicatives sur les probabilités d'appartenance aux différentes catégories de la variable dépendante, en comparaison à une catégorie de référence. Pour évaluer la performance globale du modèle, nous examinerons des métriques clés telles que la précision globale, la précision par classe et l'intervalle de confiance. Ces indicateurs fourniront une évaluation complète de la qualité de l'ajustement et des capacités prédictives

du modèle.

L'identification des variables les plus significatives se fera à travers l'interprétation des coefficients estimés. Un coefficient positif indique que la modalité de la variable explicative augmente la probabilité d'appartenir à une catégorie spécifique de la variable cible (type d'erreur), par rapport à la catégorie de référence, qui est « Pauvre » dans notre cas. À l'inverse, un coefficient négatif suggère une diminution de cette probabilité. Il est également important de noter que chaque variable explicative possède sa propre modalité de référence, ce qui influence l'interprétation des coefficients obtenus.

Chapitre 3

Présentation et interprétation des résultats de l'analyse bivariée, des tests statistiques et du modèle

...

Dans ce chapitre, une analyse détaillée de la pauvreté réelle et prédite est réalisée. Les ressemblances et les différences entre les ménages pauvres réels et prédits sont mises en évidence. Une analyse descriptive est également menée afin d'examiner les erreurs de prédiction du modèle. Des tests statistiques sont effectués pour identifier les variables significativement liées aux types d'erreurs du modèle. Enfin, un modèle multinomial est estimé pour déterminer les facteurs explicatifs des erreurs observées.

3.1 Analyse descriptive

Dans cette partie, nous allons dans un premier temps croiser l'indicateur de pauvreté réel avec les variables explicatives, afin de dégager le profil des ménages réellement pauvres. Ensuite, l'indicateur de pauvreté prédit sera comparé avec ces mêmes variables pour identifier les caractéristiques des ménages prédits comme pauvres. Enfin, la variable relative au type d'erreur sera croisée avec les variables explicatives, dans le but d'approfondir la compréhension des facteurs susceptibles de provoquer des erreurs de classification, en particulier celles d'inclusion et d'exclusion. Cette démarche permettra de mettre en lumière les facteurs discriminants et d'identifier les domaines nécessitant des ajustements dans les modèles de ciblage de la pauvreté.

3.1.1 Analyse croisée des biens des ménages et des indicateurs de pauvreté : Réel vs Prédit

L'analyse croisée des biens des ménages avec les indicateurs de pauvreté réels et prédits permet de mieux comprendre les différences entre les ménages réellement pauvres et ceux identifiés comme pauvres par les modèles prédictifs. Les résultats sont consignés dans le tableau ci-dessous.

TABLEAU 3.1 – Distribution de l'indicateur de pauvreté réel et prédit suivant la possession d'appareils d'équipement

	Milieu urbain		Milieu rural	
	Pauvre	Pauvre prédit	Pauvre	Pauvre prédit
Ménage utilisant un frigo (%)	24,04	17,45	6,29	4,86
Ménage utilisant un ventilateur (%)	36,31	26,85	11,26	12
Ménage utilisant une bonbonne de gaz (%)	39,88	30,2	22,19	22,86
Ménage possédant une voiture (%)	1,19	2,01	0,33	0,86
Ménage possédant un fer à charbon (%)	37,5	34,9	34,11	36,57
Ménage possédant un ordinateur (%)	2,98	3,36	0,66	1,14
Ménage possédant un fer électrique (%)	0,6	0	0	0,29

Source : EHCVM 2022, calculs de l'auteur

Ce tableau montre qu'en milieu urbain, les pauvres réels et les pauvres prédits présentent des ressemblances sur certaines variables, notamment l'utilisation du fer à charbon, où les proportions sont respectivement de 37,5% pour les pauvres réels et 34,9% pour les pauvres prédits. De même, pour l'accès à un ordinateur, les proportions sont proches, avec 2,98 % pour les pauvres réels et 3,36% pour les pauvres prédits, tout comme l'usage du fer électrique, où les proportions sont respectivement de 0,6% et 0%.

Cependant, des dissemblances marquées sont observées pour d'autres variables. Par exemple, la possession d'un frigo est rapportée à 24,04% chez les pauvres réels contre seulement 17,45% pour les pauvres prédits. De même, la possession de ventilateurs varie de 36,31% pour les pauvres réels à 26,85% pour les pauvres prédits. Enfin, des écarts sont notés entre les pauvres réels et les pauvres prédits pour l'utilisation du gaz (39,88% contre 30,2%) et la possession de voitures (1,19% contre 2,01%). Ces proportions montrent que les ménages prédits comme pauvres sont globalement moins dotés en biens matériels en comparaison aux ménages réellement pauvres en milieu urbain.

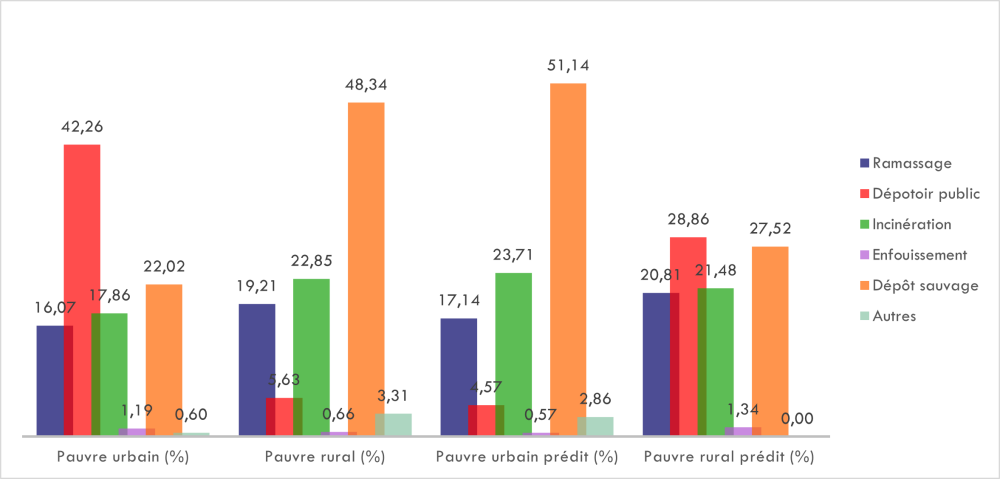
En milieu rural, les ressemblances entre les pauvres réels et les pauvres prédits se manifestent principalement dans l'utilisation du gaz (22,19% pour les pauvres réels et 22,86% pour les pauvres prédits) et du fer à charbon (34,11% contre 36,57%). Ces similitudes indiquent une relative cohérence dans l'identification de ces ménages par le modèle.

Cependant, des dissemblances significatives sont également observées pour plusieurs variables. Par exemple, la possession d'un frigo est plus forte chez les pauvres réels (6,29%) que chez les pauvres prédits (4,86%). De même, l'accès à un ventilateur est légèrement supérieur chez les pauvres prédits (12%) par rapport aux pauvres réels (11,26%). Des écarts relativement légers sont également visibles pour la possession de voitures (0,33% contre 0,86%), d'ordinateurs (0,66% contre 1,14%) et de fers électriques (0% contre 0,29%), indiquant des divergences dans la reconnaissance des ménages pauvres sur ces aspects spécifiques. Aucune conclusion évidente ne peut être tirée de ces écarts. Ce constat est imputable aux faibles effectifs notés dans l'échantillon test en zone rurale.

3.1.2 Analyse de la pauvreté réelle et prédite en fonction du mode d'évacuation des ordures ménagères

Le mode d'évacuation des ordures est un indicateur important du niveau de développement des infrastructures d'assainissement dans une zone géographique donnée. Cet aspect de la vie quotidienne reflète non seulement les conditions sanitaires d'un ménage, mais aussi son accès aux services publics de base. Dans cette section, nous examinerons la pauvreté réelle et prédite en fonction du mode d'évacuation des ordures, en croisant les données sur la gestion des déchets avec les indicateurs de pauvreté. Les principaux résultats sont présentés dans le graphique ci-après.

FIGURE 3.1 – Distribution de l'indicateur de pauvreté réel et prédit suivant le mode d'évacuation des ordures ménagères (%)



Source : EHCVM 2022, calculs de l'auteur

En milieu urbain, des disparités importantes se remarquent entre les pauvres réels et les pauvres prédits sur les modes d'évacuation des ordures ménagères. Les pauvres réels privilégient davantage les dépotoirs publics (42,26%) par rapport aux pauvres prédits (17,14%). Par contre, le dépôt sauvage est plus fréquent chez les pauvres prédits (51,14%) comparé aux pauvres réels (22,02%), marquant une différence importante dans la perception des pratiques d'évacuation. Les autres méthodes comme l'incinération (16,07% pour les réels et 23,71% pour les prédits) montrent également des écarts.

En milieu rural, les modes d'évacuation des ordures ménagères diffèrent également entre les pauvres réels et les pauvres prédits. Les dépôts sauvages prédominent, atteignant 48,34 % chez les pauvres réels contre 27,52 % pour les pauvres prédits. À l'inverse, les pauvres prédits utilisent plus fréquemment les dépotoirs publics (28,86 %) que les pauvres réels (19,21 %). Le ramassage des ordures ménagères reste limité, bien qu'il soit légèrement plus courant chez les pauvres prédits (20,81 %) que chez les pauvres réels (5,63 %). Les autres méthodes (enfouissement, incinération, ou autres) sont peu significatives, montrant des pourcentages très faibles, mais leur proportion reste plus élevée chez les pauvres réels.

Ces résultats mettent en lumière des divergences dans les modes d'évacuation des ordures ménagères entre les pauvres réels et prédits, reflétant potentiellement des biais dans l'identification des conditions de vie liées à ces pratiques.

3.1.3 Analyse de pauvreté réelle et prédite en fonction des sources d'approvisionnement en eau

Pour ce qui est de l'eau, son accès est un critère fondamental pour évaluer le niveau de vie d'un ménage, et il est souvent utilisé comme un indicateur clé dans la mesure de la pauvreté. Dans cette section, nous croiserons les données relatives à l'approvisionnement en eau avec les indicateurs de pauvreté réels et prédits. Les résultats sont donnés dans le tableau ci-dessous.

TABLEAU 3.2 – Distribution de l'indicateur de pauvreté réel et prédit suivant les sources d'approvisionnement en eau (%)

	Milieu urbain		Milieu rural	
	Pauvre	Pauvre prédit	Pauvre	Pauvre prédit
Ménage utilisant un robinet (%)	66,07	51,68	56,62	55,71
Ménage utilisant un puits non protégé (%)	19,64	28,86	25,83	26,29
Ménage utilisant un puit protégé (%)	8,93	12,08	15,89	15,71
Ménage utilisant une eau en surface (%)	0	0	0,66	0,86
Ménage utilisant une autre source (%)	5,36	7,38	0,99	1,43

Source : EHCVM 2022, calculs de l'auteur

Les résultats révèlent qu'en milieu urbain, les ménages pauvres réels et prédits présentent des similitudes pour certaines sources d'eau. Par exemple, l'utilisation de puits non protégés est de 19,64% pour les pauvres réels et de 28,86% pour les pauvres prédits, traduisant une certaine cohérence dans l'identification de ces ménages. De même, les proportions pour les puits protégés sont proches, avec respectivement 8,93% pour les pauvres réels et 12,08% pour les pauvres prédits. Cependant, des écarts notables apparaissent pour l'utilisation de robinets, où 66,07% des pauvres réels y ont accès

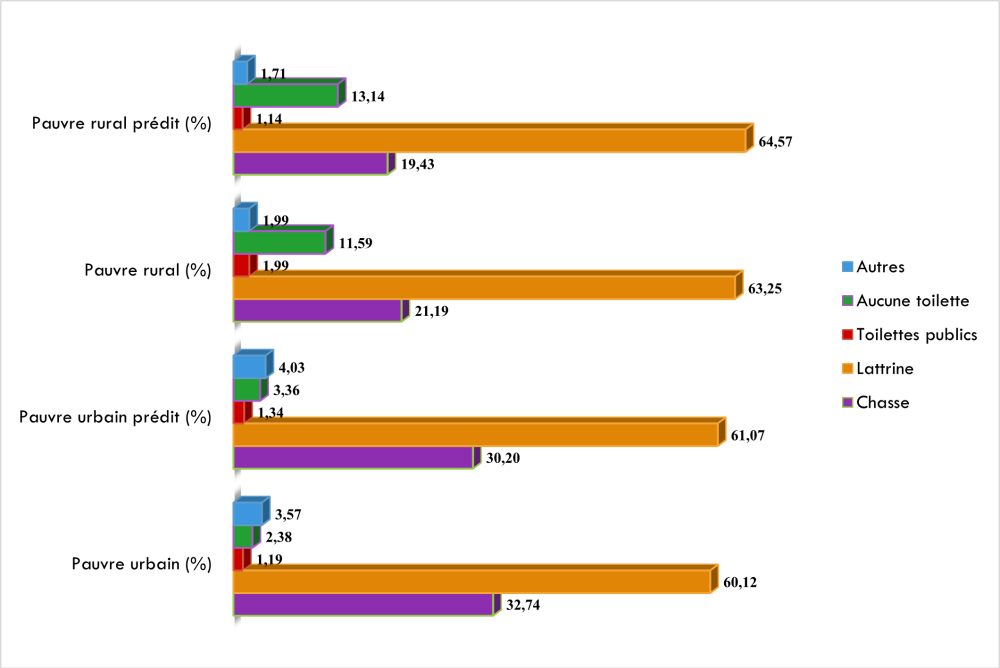
contre seulement 51,68% pour les pauvres prédits. L'utilisation d'autres sources d'eau est également plus fréquente chez les pauvres prédits (7,38%) comparée aux pauvres réels (5,36%). Ces différences traduisent une légère sous-estimation de l'accès aux infrastructures modernes d'approvisionnement en eau chez les ménages pauvres urbains identifiés par le modèle.

En milieu rural, les similitudes entre les ménages pauvres réels et prédits sont évidentes pour l'utilisation des puits non protégés (25,83% pour les pauvres réels et 26,29% pour les pauvres prédits) et des puits protégés (15,89% contre 15,71%). Ces proportions indiquent une bonne capacité du modèle à capturer ces caractéristiques. Cependant, des divergences sont observées pour l'utilisation de robinets, qui est légèrement plus élevée chez les pauvres réels (56,62%) que chez les pauvres prédits (55,71%). L'utilisation de l'eau en surface est aussi marginalement plus fréquente chez les pauvres prédits (0,86%) que chez les pauvres réels (0,66%), bien que ces proportions restent faibles. Ces écarts mineurs suggèrent que le modèle reflète globalement bien les réalités du milieu rural, mais pourrait sous-estimer l'accès à des sources d'eau relativement modernes comme les robinets.

3.1.4 Analyse de pauvreté réelle et prédite en fonction des sources d'approvisionnement en infrastructures sanitaires

Les infrastructures sanitaires sont des éléments importants pour déterminer la qualité de vie d'un ménage. Dans cette partie de l'analyse, nous examinerons l'accès des ménages à des infrastructures sanitaires adéquates, en les mettant en relation avec les indicateurs de pauvreté réels et prédits. Cette analyse nous permettra d'évaluer l'impact des conditions sanitaires sur la pauvreté perçue et de voir si les modèles prédictifs tiennent compte de cette dimension essentielle de la vie quotidienne dans le ciblage des ménages pauvres.

FIGURE 3.2 – Distribution de l'indicateur de pauvreté réel et prédit suivant le type sanitaire (%)



Source : EHCVM 2022, calculs de l'auteur

En milieu urbain, les pauvres réels et les pauvres prédits montrent des similarités marquées pour l'utilisation des latrines, qui représentent 60,12% pour les pauvres réels contre 61,07% pour les pauvres prédits. De même, pour les toilettes à chasse, les proportions sont relativement proches, avec 32,74% chez les pauvres réels et 30,20% pour les pauvres prédits. Ces similitudes indiquent que le modèle parvient globalement à identifier correctement les ménages pauvres selon ces critères d'accès aux installations sanitaires. Cependant, des dissemblances notables apparaissent dans d'autres catégories. Par exemple, l'absence totale de toilettes concerne 2,38% des pauvres réels contre 3,36% pour les pauvres prédits, traduisant une légère surestimation par le modèle. De même, l'utilisation des toilettes publiques est faible mais plus présente chez les pauvres prédits (1,34%) que chez les pauvres réels (1,19%).

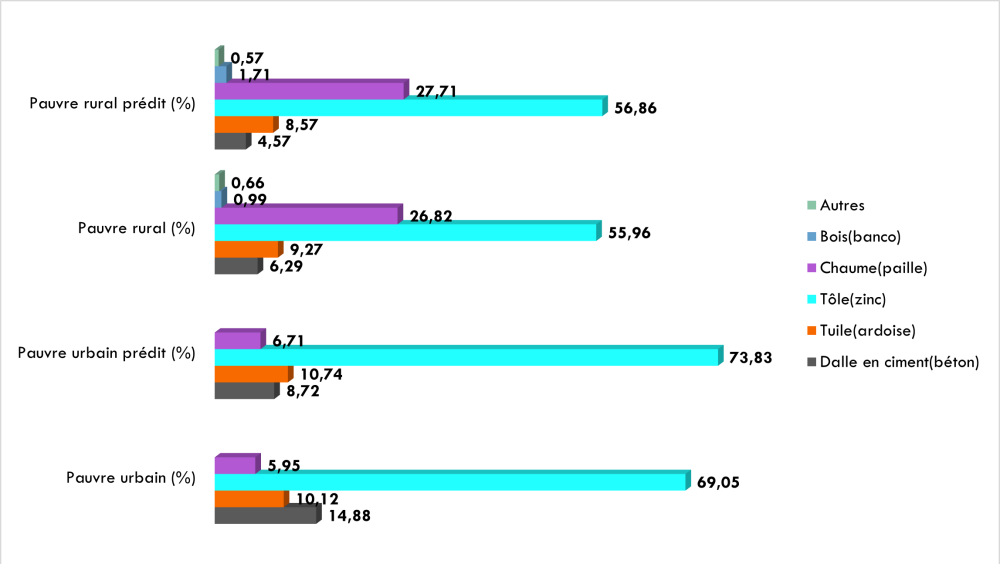
En milieu rural, les latrines constituent également la principale installation sanitaire pour les pauvres réels (63,25%) et les pauvres prédits (64,57%), démontrant une forte ressemblance dans cette catégorie. De même, les toilettes à chasse sont utilisées par 21,19% des pauvres réels et 19,43% des pauvres prédits, montrant une légère sous-estimation du modèle. En revanche, des écarts apparaissent pour d'autres types d'installations. Par exemple, l'absence totale de toilettes concerne 11,59% des pauvres réels contre 13,14%

des pauvres prédits, ce qui montre une surestimation de cette catégorie par le modèle. L'usage des toilettes publiques est identique pour les deux groupes (1,99%). Dans les deux milieux, urbain et rural, le modèle parvient globalement à identifier correctement les principales tendances d'accès aux installations sanitaires, en particulier pour les latrines et les toilettes à chasse. Toutefois, des divergences apparaissent pour les catégories moins courantes, comme l'absence totale de toilettes ou les toilettes publiques, indiquant que le modèle pourrait surestimer ou sous-estimer certains aspects des conditions sanitaires spécifiques. Ces écarts pourraient influencer la précision globale de l'identification des ménages pauvres, notamment en milieu rural où les conditions sont plus précaires.

3.1.5 Analyse de pauvreté réelle et prédite en fonction des matériaux des toits

Les matériaux de construction utilisés pour les toits, sont des indicateurs importants de la qualité du logement et, par extension, du niveau de pauvreté d'un ménage. Les matériaux plus durables et résistants sont souvent associés à un niveau de vie plus élevé, tandis que ceux utilisés par les ménages pauvres sont souvent moins solides et plus vulnérables aux conditions climatiques. Dans cette section, nous présentons les résultats pour notre analyse dans un graphique.

FIGURE 3.3 – Distribution de l'indicateur de pauvreté réel et prédit suivant le type de matériaux de construction des toits (%)



Source : EHCVM 2022, calculs de l'auteur

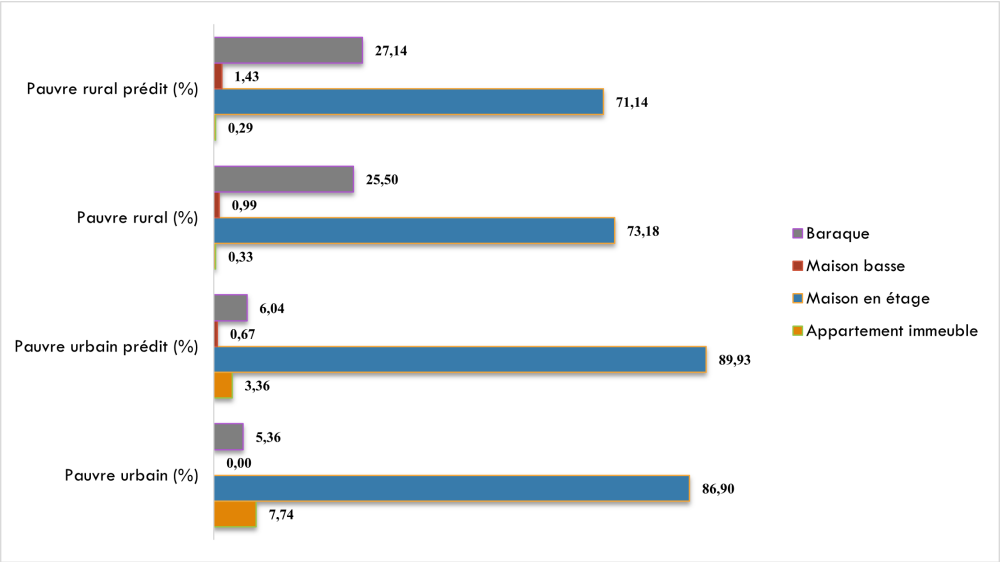
En milieu urbain, les pauvres réels et les pauvres prédits présentent des ressemblances notables sur certaines modalités, notamment l'utilisation de la tôle en zinc, où les proportions sont respectivement de 69,05% pour les pauvres réels et 73,83% pour les pauvres prédits. De même, l'utilisation de la tuile (ardoise) est similaire, avec 10,12% chez les pauvres réels contre 10,74% pour les pauvres prédits. Cependant, des dissemblances sont observées pour d'autres matériaux. Par exemple, la chaume est rapportée à 14,88% chez les pauvres réels contre 8,72% pour les pauvres prédits, traduisant un biais potentiel dans la prédiction des logements plus précaires.

En milieu rural, les ressemblances entre les pauvres réels et prédits se manifestent principalement dans l'usage de la tôle (zinc) (56,96% contre 56,86%).

3.1.6 Analyse de pauvreté réelle et prédite en fonction des types de logement

Le type de logement est un autre facteur déterminant dans l'évaluation des conditions de vie des ménages. Que ce soit une maison en dur, une habitation précaire, ou une location, le type de logement reflète largement la situation économique d'un ménage. Dans cette section, nous croiserons le type de logement avec les indicateurs de pauvreté réels et prédits et le résultat est dans le graphique suivant.

FIGURE 3.4 – Distribution de l'indicateur de pauvreté réel et prédit suivant le type de logement (%)



Source : EHCVM 2022, calculs de l'auteur

En milieu urbain, la majorité des pauvres réels (86,9%) et prédits (89,93%) vivent dans des maisons en étage, ce qui indique une cohérence dans la prédiction pour cette catégorie. Les logements de type baraque montrent aussi une certaine similitude (5,36% contre 6,04%).

En milieu rural, les pauvres réels et prédits présentent une forte ressemblance concernant les maisons en étage (71% contre 73%). Cependant, l'habitat de type baraque est légèrement surestimé par le modèle (25,50% chez les pauvres réels contre 27,74% chez les pauvres prédits). Cette différence peut influencer l'identification des ménages les plus vulnérables.

3.1.7 Analyse de pauvreté réelle et prédite en fonction du mode d'éclairage

Le mode d'éclairage quant à lui, est un indicateur de base du développement infrastructurel d'une communauté, car il reflète l'accès à l'énergie et la capacité d'un ménage à répondre à ses besoins essentiels en termes d'éclairage. Les ménages pauvres sont souvent contraints de recourir à des sources d'éclairage moins fiables et plus coûteuses. Dans cette partie nous présentons graphiquement la distribution dans le cadre du travail effectué.

FIGURE 3.5 – Distribution de l'indicateur de pauvreté réel et prédit suivant le mode d'éclairage (%)



Source : EHCVM 2022, calculs de l'auteur

En milieu urbain, les pauvres réels et prédits utilisent principalement l'électricité fournie par Senelec, avec des proportions proches (70,24% pour les pauvres réels et 62,42% pour les pauvres prédits). L'usage des lampes rechargeables est également proche (13,69% contre 17,45%). Cependant, des écarts sont notés pour les lampes solaires (8,93% chez les pauvres réels contre 14,09% pour les pauvres prédits), indiquant une surestimation des sources d'éclairage moins modernes.
En milieu rural, les similitudes sont marquées pour les lampes artisanales (45,36% contre 46,29%). Toutefois, l'utilisation des lampes solaires est légèrement surestimée par le modèle (26,86% chez les pauvres prédits contre 23,84% chez les pauvres réels), ce qui pourrait entraîner une sous-identification des ménages les plus démunis. Cette analyse met en évidence une cohérence générale entre les pauvres réels et les pauvres prédits pour plusieurs variables essentielles, mais aussi des divergences notables. Ces écarts soulignent l'importance de mieux affiner les prédictions, notamment en tenant compte des matériaux de construction et des conditions de logement en milieu rural.

3.1.8 Analyse de pauvreté réelle et prédite en fonction du mode d'évacuation des eaux usées

Le mode d'évacuation des eaux usées est un autre critère clé dans l'évaluation des conditions de vie et de la pauvreté. Un système d'assainissement adéquat est essentiel pour la santé publique et le bien-être des ménages, et son absence est souvent le reflet de conditions de vie précaires. Cette section portera sur l'analyse des données relatives à l'évacuation des eaux usées, en les croisant avec les indicateurs de pauvreté réelle et prédite. Le résultat est donné dans le tableau suivant :

TABLEAU 3.3 – Distribution de l'indicateur de pauvreté réel et prédit suivant le mode d'évacuation des eaux usées (%)

	Milieu urbain		Milieu rural	
	Pauvre	Pauvre prédit	Pauvre	Pauvre prédit
Evacuation dans un puisard (%)	7,14	5,37	2,32	2,86
Evacuation dans des égouts (%)	8,33	8,05	1,66	3,14
Evacuation dans des trous creusés (%)	14,29	13,42	14,24	12,86
Evacuation dans la nature (%)	68,45	71,14	78,15	78
Evacuation dans d'autres modes (%)	1,79	2,01	3,64	3,14

Source : EHCVM 2022, calculs de l'auteur

En milieu urbain, les pauvres réels et les pauvres prédits montrent des proportions relativement proches pour certains modes d'évacuation des eaux usées. Par exemple, les égouts sont utilisés par 8,33% des pauvres réels contre 8,05% des pauvres prédits, traduisant une bonne identification par le modèle. De même, les proportions pour les trous creusés restent similaires (14,29% pour les pauvres réels et 13,42% pour les pauvres prédits). Cependant, des différences apparaissent pour l'évacuation dans la nature, qui est plus fréquente chez les pauvres prédits (71,14%) que chez les pauvres réels (68,45%). Les proportions pour les puisards sont également plus faibles chez les pauvres prédits (5,37%) comparées aux pauvres réels (7,14%). Ces écarts mettent en lumière une tendance du modèle à surestimer l'utilisation de moyens rudimentaires d'évacuation des eaux usées dans ce milieu.

En milieu rural, les ressemblances entre les pauvres réels et les pauvres prédits se concentrent autour de l'évacuation dans la nature, qui est dominante avec 78,15% chez les pauvres réels et 78,00% chez les pauvres prédits. Ces proportions indiquent une forte cohérence dans la reconnaissance des ménages partageant ces caractéristiques. Cependant, des dissemblances légères sont notées pour les puisards (2,32% pour les pauvres réels contre 2,86% pour les pauvres prédits) et les égouts (1,66% contre 3,14%). Ces différences

traduisent une possible surestimation de l'accès aux infrastructures d'évacuation moderne par le modèle dans les zones rurales, bien que ces proportions restent faibles. Les résultats confirment globalement la prédominance de l'évacuation rudimentaire dans ce milieu, mais le modèle pourrait encore être affiné pour mieux capturer les nuances dans les modes d'évacuation utilisés.

3.2 Analyse des erreurs

Après avoir établi un profil détaillé des ménages en utilisant les indicateurs réels et prédits de pauvreté, il devient essentiel de se pencher sur l'analyse des erreurs de prédiction. Cette étape est primordiale, car elle permet d'identifier les mécanismes sous-jacents des erreurs d'inclusion (classification des ménages non pauvres comme pauvres) et d'exclusion (classification des ménages pauvres comme non pauvres). L'objectif est de comprendre pourquoi ces erreurs surviennent et quels facteurs explicatifs peuvent être à l'origine de ces écarts.

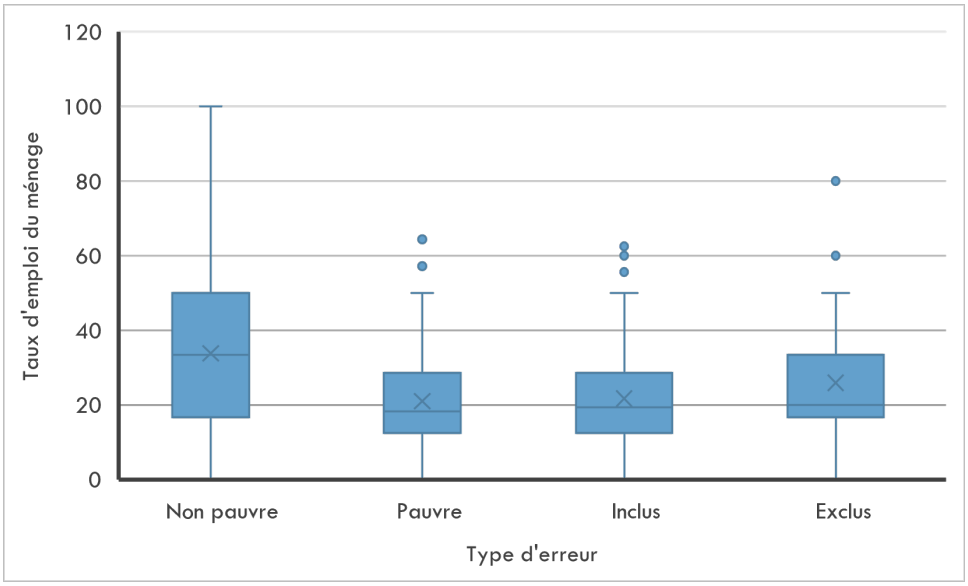
3.2.1 Milieu rural

L'analyse des erreurs de prédiction commence par le milieu rural, où nous allons explorer plusieurs variables susceptibles d'expliquer les erreurs d'inclusion et d'exclusion. Parmi ces variables, nous nous concentrerons notamment sur le mode d'évacuation des ordures ménagères, les sources d'approvisionnement en eau, la taille du ménage, le taux de promiscuité et le taux d'emploi du ménage.

3.2.1.1 Distribution du taux d'emploi du ménage selon le type d'erreur

Le taux d'emploi est un indicateur clé permettant de distinguer les ménages. Les erreurs de classification semblent plus fréquentes pour les ménages avec des niveaux d'emploi intermédiaires comme le montre le graphique suivant :

FIGURE 3.6 – Distribution du taux d'emploi du ménage selon le type d'erreur (%)



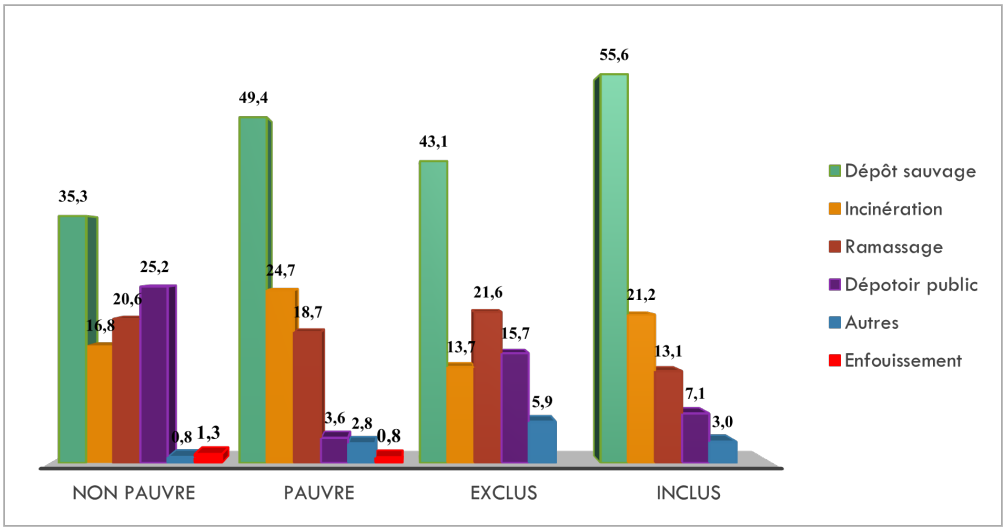
Source : EHCVM 2022, calculs de l'auteur

Les ménages non pauvres et exclus présentent ont un taux d'emploi médian relativement élevé, autour de 35%. La distribution est large, avec plusieurs valeurs extrêmes (outliers) qui dépassent les 80%, et atteignent parfois 100%. Les ménages pauvres et inclus ont quant à eux, un taux d'emploi nettement plus faible, avec une médiane d'environ 20%. La variabilité est également plus faible, avec moins de valeurs extrêmes.

3.2.1.2 Distribution du mode d'évacuation des ordures ménagères selon le type d'erreur

Le graphique ci-dessous donne la distribution des mode d'évacuation des ordures ménagères selon le type d'erreur.

FIGURE 3.7 – Distribution du mode d'évacuation des ordures ménagères selon le type d'erreur en milieu rural (%)



Source : EHCVM 2022, calculs de l'auteur

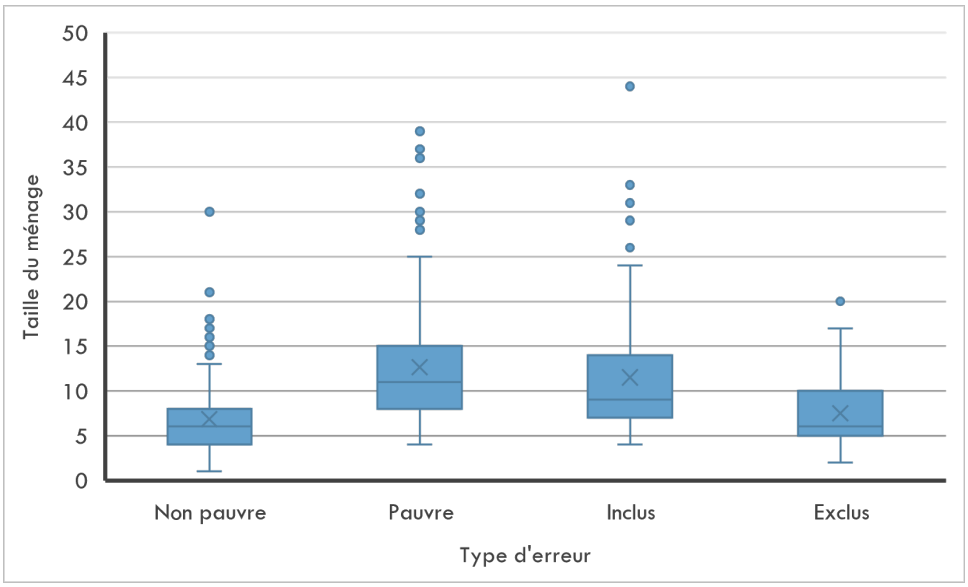
Les ménages pauvres correctement prédits et ceux faussement inclus dans la catégorie des pauvres tendent à avoir un profil commun en termes de mode d'évacuation des ordures. De même, les ménages non pauvres correctement prédits et les exclus partagent également des caractéristiques communes. Par exemple, tout comme les ménages pauvres utilisent plus les dépôts sauvages que les ménages non pauvres (49,4% contre 35,3%), on observe que les ménages faussement inclus dans la catégorie pauvre utilisent plus souvent ce mode d'évacuation des ordures comparé aux ménages pauvres exclus (55,6% contre 43,1%). Le même constat peut être observé sur la plupart des autres modes d'évacuations. Cette observation suggère que le mode d'évacuation des ordures pourrait être un facteur explicatif des erreurs de classification, les ménages utilisant des modes plus précaires d'évacuation des ordures étant plus susceptibles d'être classés comme pauvres.

3.2.1.3 Distribution de la taille du ménage selon le type d'erreur

La taille du ménage semble également être un facteur déterminant dans les erreurs de classification. En effet, les ménages nombreux sont plus susceptibles d'être classés comme pauvres, même s'ils ne le sont pas nécessairement, ce qui pourrait expliquer les erreurs d'inclusion. Le graphique suivant nous donne une distribution de taille du ménage selon

le type d'erreur.

FIGURE 3.8 – Distribution de la taille du ménage selon le type d'erreur



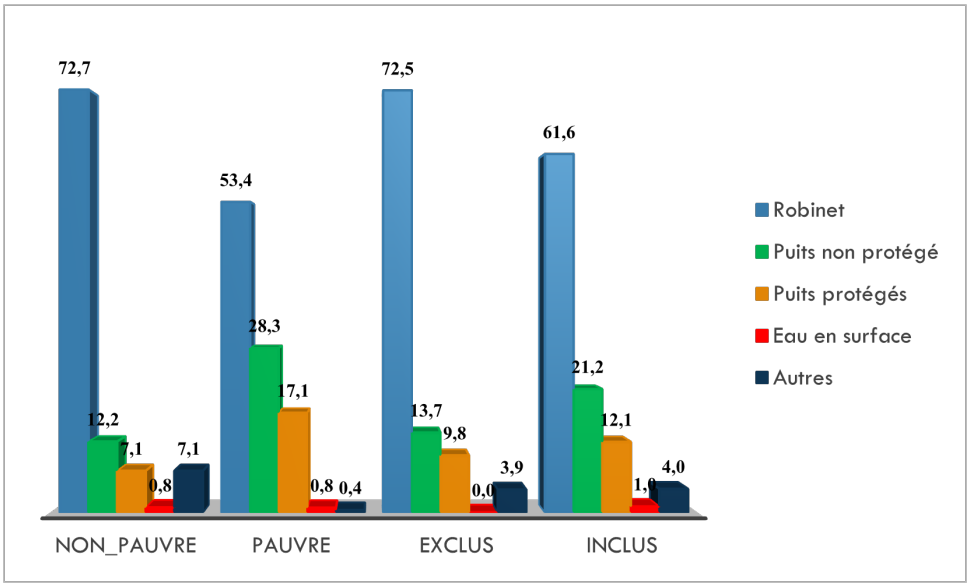
Source : EHCVM 2022, calculs de l'auteur

Les ménages non pauvres et exclus ont des tailles de ménage plus réduites, avec une médiane autour de 6 à 7 personnes. Les distributions sont serrées, et les valeurs aberrantes sont limitées (au plus 30). Pour ce qui est des ménages pauvres et inclus, ils présentent des tailles de ménage plus importantes, avec des médianes autour de 12 à 13 personnes. Les distributions sont plus étendues, avec plusieurs valeurs aberrantes qui avoisinent 44 personnes.

3.2.1.4 Distribution des sources d'approvisionnement en eau selon le type d'erreur

Les résultats de l'analyse sont consignés dans le graphique suivant :

FIGURE 3.9 – Distribution des sources d'approvisionnement en eau selon le type d'erreur en milieu rural (%)



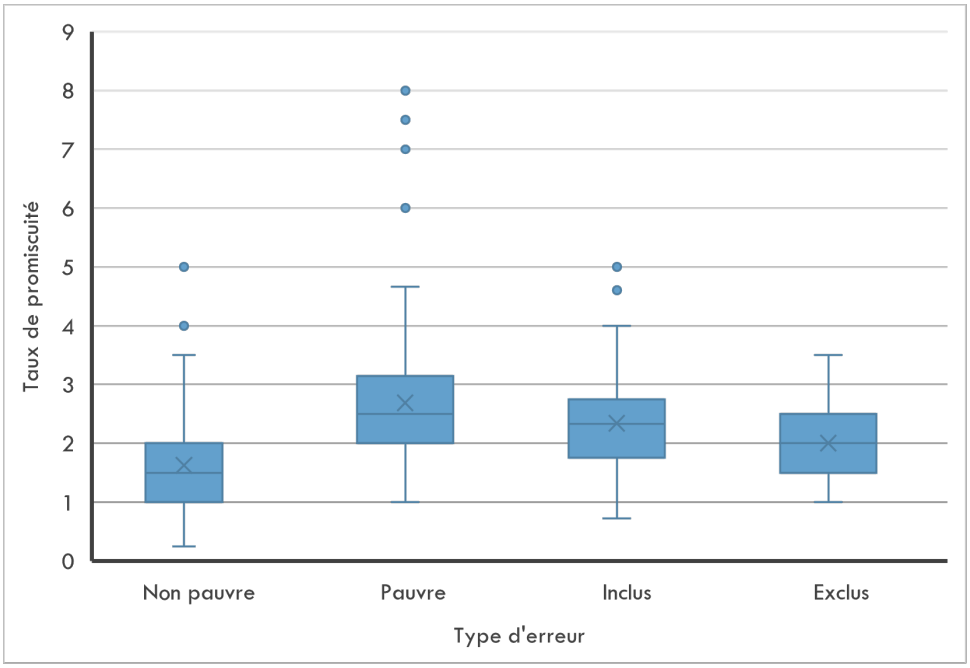
Source : EHCVM 2022, calculs de l'auteur

Les ménages non pauvres correctement classés et ceux faussement exclus présentent une forte proportion d'accès à l'eau de robinet, avec respectivement 72,7% et 72,5%. En revanche, les ménages pauvres correctement prédits et ceux faussement inclus dans la catégorie pauvre montrent un accès plus limité à l'eau de robinet (53,4% et 61,6%). On observe que les puits non protégés sont davantage utilisés par les ménages pauvres (17,1%) et inclus (21,2%) comparés aux non pauvres (11,2%) et exclus (13,7%). Cette tendance suggère que l'accès à des sources d'eau plus précaires, comme les puits non protégés, est un indicateur associé à la pauvreté. Les ménages utilisant des modes d'accès à l'eau plus précaires sont ainsi plus susceptibles d'être classés comme pauvres.

3.2.1.5 Distribution du taux de promiscuité selon le type d'erreur

Le taux de promiscuité qui est le nombre de personnes par pièce habitable, est un facteur clé pour différencier les ménages pauvres des non pauvres. Le graphique ci-dessous donne la distribution de ce taux suivant le type d'erreur.

FIGURE 3.10 – Distribution du taux de promiscuité selon le type d'erreur



Source : EHCVM 2022, calculs de l'auteur

Les ménages non pauvres et les ménages exclus montrent un faible taux de promiscuité, avec une médiane comprise entre 1 et 2. La distribution est relativement resserrée, ce qui signifie que ces ménages disposent généralement de plus d'espace par personne. S'agissant des ménages pauvres et inclus, ils ont des taux de promiscuité plus élevés, avec une médiane autour de 2 à 3. Certains ménages dépassent même 5 et atteignent 8, indiquant un surpeuplement important.

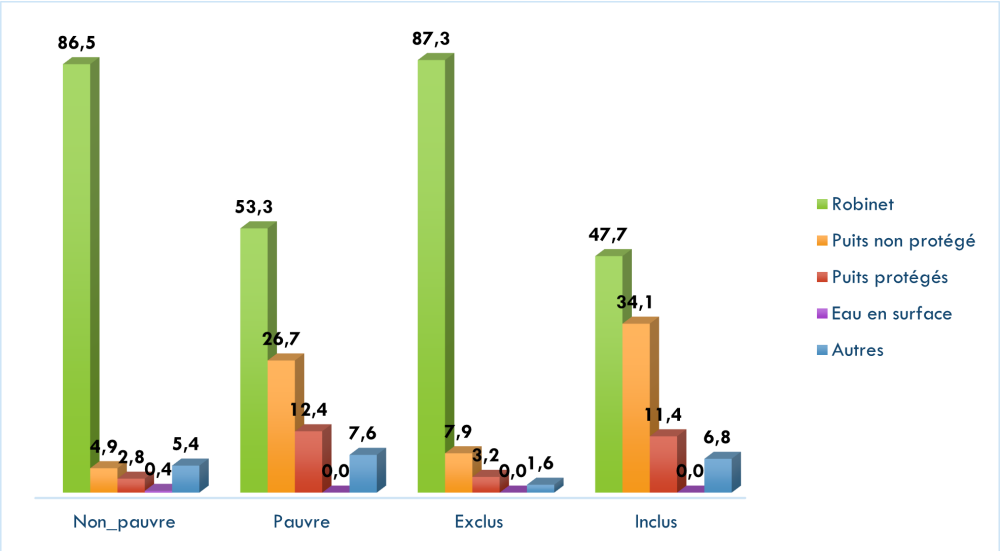
3.2.2 Milieu urbain

L'analyse des erreurs de prédiction en milieu urbain met en évidence des différences notables par rapport au milieu rural. En effet, les résultats révèlent que le taux d'erreur d'inclusion en milieu urbain atteint 29,5%, tandis que le taux d'erreur d'exclusion s'élève à 37,5%. Ces écarts suggèrent que, dans les zones urbaines, un nombre important de ménages non pauvres sont classés à tort parmi les ménages pauvres, tandis qu'un nombre significatif de ménages réellement pauvres sont omis du ciblage. Cette partie de l'analyse se concentrera sur l'examen des variables influençant ces erreurs. L'analyse concerne le mode d'évacuation des ordures et les sources d'eau. Le tableau résumant les résultats des autres variables se trouve en annexe.

3.2.2.1 Distribution du type d'erreur par source d'eau

Le graphique ci-dessous montre la distribution des sources d'eau selon le type d'erreur.

FIGURE 3.11 – Distribution des sources d'approvisionnement en eau selon le type d'erreur en milieu urbain (%)



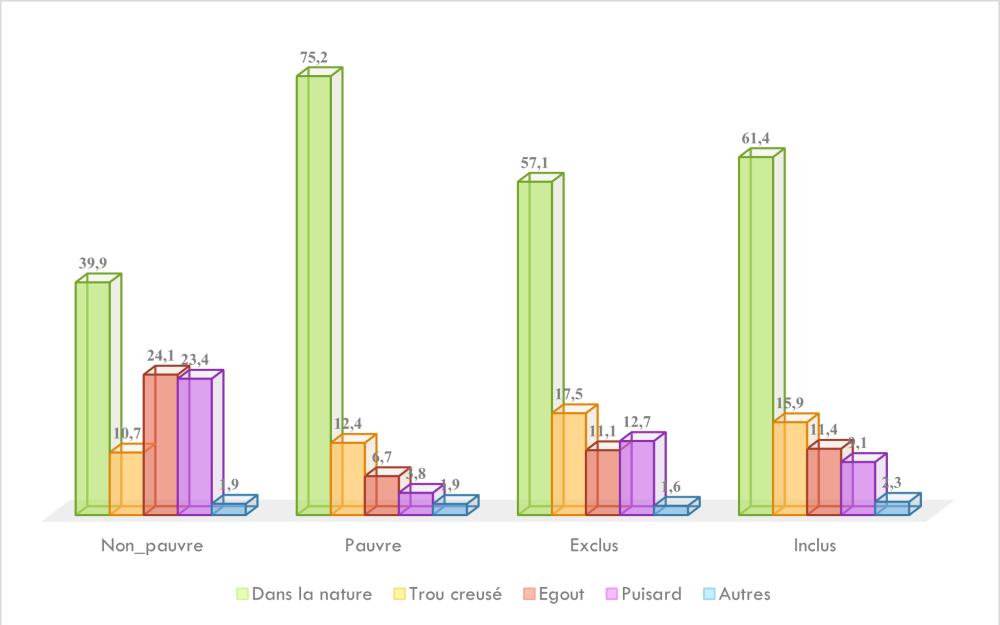
Source : EHCVM 2022, calculs de l'auteur

Les ménages non pauvres correctement classés et les exclus montrent un fort accès aux sources d'eau de meilleure qualité, avec respectivement 86,5% et 87,3% de ceux-ci qui ont accès à l'eau du robinet. À l'inverse, les ménages pauvres et inclus présentent un accès réduit à l'eau du robinet (53,3% pour les pauvres et 47,7% pour les inclus) et utilisent également des sources d'eaux comme les puits non protégés (26.7% et 34,1%).

3.2.2.2 Distribution des modes d'évacuation des eaux usées selon le type d'erreur

Le graphique ci-dessous donne la distribution des modes d'évacuation des eaux usées selon le type d'erreur.

FIGURE 3.12 – Distribution des modes d'évacuation des eaux usées selon le type d'erreur(%)



Source : EHCVM 2022, calculs de l'auteur

Les ménages pauvres et inclus évacuent en majorité leurs eaux usées dans la nature (75,2% et 61,4%) tandis que les ménages non pauvres et exclus emploient ce mode d'évacuation de façon modérée. Les ménages pauvres et incluent emploient quant à eux les autres modes d'évacuation des eaux usées dans le même c'est-à-dire qu'en terme de pourcentage, après la modalité «dans la nature» viennent dans l'ordre cité les modalités suivantes : « trou creusé », égout », « puisard » et « autres ». Toutefois, pour les non pauvres et les exclus, on n'a pas cette tendance.

3.3 Relation entre chaque variable prédictive et la variable type d'erreur

3.3.1 Milieu urbain

Le tableau ci-dessous présente les résultats des tests de Khi-deux et de Kruskal-Wallis appliqués à différentes variables explicatives pour évaluer leur lien avec les types d'erreurs de prédiction. Ces tests permettent de distinguer les variables explicatives significativement liées au type d'erreurs de celles qui ne le sont pas. Et de les classer par ordre de significativité.

TABLEAU 3.4 – Résultats des tests statistiques en milieu urbain

Variables	P-value	Df (degré de liberté)	Statistique de test
Mode d'évacuation des ordures ménagères	3,93e-16***	15	107,98
Source d'eau	< 2,2e-16***	12	115,87
Matériau du toit	< 2,2e-16***	15	124,93
Type sanitaire	< 2,2e-16***	12	112,29
Matériau mur	< 2,2e-16***	9	132,89
Type de logement	1,34E-12**	3	8,7
Nature du sol	< 2,2e-16***	9	171,77
Mode d'évacuation des eaux usées	5,87E-05*	12	70,28
Age	0,1	3	4,91
Taille du ménage	< 2,2e-16***	3	133,34
Taux d'emploi	3,69E-09**	3	42,17
Taux de promiscuité	< 2,2e-16***	3	140,48
Statut d'occupation	0,00334	12	29,48
Région	1,46E-14**	39	145,75
*** : relation forte	** : relation modérée	* : relation faible	

Source : EHCVM 2022, calculs de l'auteur

Les résultats des tests montrent des différences significatives entre les variables explicatives et la variable cible. Les variables les plus explicatives, avec une p-value inférieure à 2,2e-16, sont : le taux de promiscuité, la nature du sol, le matériau des murs, la taille du ménage, le matériau du toit, la source d'eau, le type de sanitaire et le mode d'évacuation des ordures ménagères. Ces variables sont fortement associées à la pauvreté et jouent un rôle clé dans la classification des ménages, ce qui reflète leur potentiel explicatif élevé. En particulier, le taux de promiscuité se distingue comme un facteur déterminant, indiquant que des conditions de logement exiguës sont un indicateur clé de pauvreté. De même, des variables liées aux infrastructures de logement, comme la nature du sol, les matériaux des murs et les matériaus du toit, témoignent de l'importance des conditions d'habitat pour évaluer le niveau de vie des ménages. La taille du ménage, qui influence directement les besoins en ressources, est également très explicative. D'autres variables, comme la région et le taux d'emploi, bien qu'elles soient significatives avec des p-values

inférieures à 0,05, présentent un impact modéré par rapport aux précédentes. Enfin, des variables comme le mode d'évacuation des eaux usées et le statut d'occupation montrent une significativité plus marginale ($0,05 \leq p < 0,1$), indiquant qu'elles sont moins explicatives dans la modélisation de la pauvreté. En conclusion, l'analyse met en évidence l'importance des conditions de logement, des caractéristiques démographiques et des infrastructures de base dans la compréhension et la prédiction de la pauvreté.

3.3.2 Milieu rural

En raison des diversités entre le milieu urbain et rural, nous allons dans ce qui suit faire les tests en milieu rural. Les résultats de ceux-ci sont résumés dans le tableau suivant :

TABLEAU 3.5 – Résultats des tests statistoques en milieu rural

Variables	P-value	Df (degré de liberté)	Statistique de test
Mode d'évacuation des ordures ménagères	4,50E-09**	15	69,981
Source d'eau	1,13E-06**	12	50,522
Matériau du toit	2,30E-12**	15	88,04
Type sanitaire	5,64E-11**	12	74,015
Matériau mur	5,06E-08**	9	51,743
Type de logement	2,05E-09**	3	59,039
Nature du sol	2,20E-16***	9	98,83
Mode d'évacuation des eaux usées	9,99E-05**		
Age	6,99E-01*	3	1,4278
Taille du ménage	2,20E-16***	3	187,05
Taux d'emploi	3,93E-12***	3	56,135
Taux de promiscuité	2,20E-16***	3	163,31
Statut d'occupation	0,0522	12	20,877
Région	2,30E-12***	39	93,823
Mode d'éclairage	9,99E-05*		
*** : relation forte	** : relation modérée	* : relation faible	

Source : EHCVM 2022, calculs de l'auteur

En milieu rural, les tests montrent que plusieurs variables explicatives sont significativement associées à la variable cible, avec des niveaux de significativité variés. Les

variables les plus explicatives, avec une p-value égale à 2,20e-16, sont la taille du ménage, le taux de promiscuité et la nature du sol. Ces variables présentent des liens très forts avec la pauvreté en milieu rural, reflétant l'importance des caractéristiques liées à l'habitat et à la démographie dans ces zones.

La taille du ménage (statistique de test : 187,05) apparaît comme un déterminant majeur, suggérant qu'une grande taille de ménage est un facteur critique de vulnérabilité en milieu rural. Le taux de promiscuité (statistique de test : 163,31) renforce cette observation, indiquant que des conditions de logement surpeuplées sont fortement corrélées à la pauvreté. Par ailleurs, la nature du sol (statistique de test : 98,83) met en évidence le rôle des caractéristiques physiques de l'habitat dans les inégalités économiques.

D'autres variables, bien que significatives avec des p-values inférieures à 0,01, sont légèrement moins explicatives, comme le matériau du toit ($p = 2,30e-12$), le type de logement, le taux d'emploi et la région. Ces variables restent néanmoins importantes pour comprendre les conditions de vie et les disparités rurales. Par exemple, la variable région (statistique de test : 93,823) illustre les disparités géographiques dans les niveaux de pauvreté.

Certaines variables, comme le mode d'évacuation des eaux usées et le mode d'éclairage, bien qu'elles soient significatives (p-values $< 0,001$), montrent une association plus faible avec la variable cible. Enfin, des variables comme l'âge ($p = 0,699$) et le statut d'occupation ($p = 0,0522$) présentent une faible significativité ou une absence d'association significative, indiquant qu'elles ne sont pas des déterminants majeurs de la pauvreté en milieu rural.

En résumé, l'analyse met en évidence que les facteurs démographiques, les caractéristiques physiques de l'habitat et les conditions régionales jouent un rôle central dans la pauvreté en milieu rural, tandis que des variables comme l'âge ou le statut d'occupation ont une importance moindre. Ces résultats renforcent la nécessité d'adopter des stratégies ciblées pour améliorer les conditions de vie en milieu rural.

3.4 Modèle logistique multinomial

Le modèle multinomial joue un rôle central dans l'analyse des erreurs de prédiction de la pauvreté, en offrant une approche robuste pour identifier les facteurs explicatifs influençant les types d'erreurs. Cette section présente la méthodologie adoptée pour construire et ajuster ce modèle, en utilisant une partie des données de la deuxime Enquête Harmonisée sur les Conditions de Vie des Ménages (EHCVM II). Le choix de ce modèle permet de traiter efficacement la variable cible à quatre modalités représentant les différentes erreurs de classification : ménages correctement classés comme pauvres ou non pauvres, ainsi que les erreurs d'inclusion et d'exclusion. La méthode d'analyse repose principalement sur l'examen des coefficients estimés par le modèle. Cet outil permet de quantifier l'influence des variables explicatives, telles que les caractéristiques du logement, l'accès aux services de base ou encore la possession de biens durables, sur les différents types d'erreurs. Les résultats obtenus fourniront un éclairage précieux sur les dynamiques sous-jacentes aux erreurs de prédiction, tout en servant de base à des recommandations pour améliorer la précision des modèles de ciblage des ménages pauvres. Les principaux résultats du modèle sont consignés dans le tableau ci-dessous :

TABLEAU 3.6 – Précision du modèle multinomial en milieu urbain et rural

	milieu rural	milieur urbain
	Métriques globales	
Précision	68,25%	80,52%
Intervalle de confiance	[59,37 ; 76,26]	[73,37 ; 86,45]
	Précision par classe	
Pauvre	78,79%	81,45%
Non pauve	85,56%	81,49%
Exclus	65,69%	53,11%
Inclus	63,75%	59,42%

Source : EHCVM 2022, calculs de l'auteur

Les résultats du modèle multinomial révèlent des performances contrastées entre les milieux rural et urbain. En milieu rural, la précision globale du modèle est de 68,25%, avec

un intervalle de confiance compris entre 59,37% et 76,26%, indiquant une performance modérée. La précision par classe montre que le modèle identifie correctement 78,79% des ménages pauvres et 85,56% des ménages non pauvres, ce qui témoigne d'une bonne capacité de prédiction pour ces deux catégories. En revanche, la précision est plus faible pour les erreurs d'exclusion (65,69%) et d'inclusion (63,75%), soulignant des difficultés à classer correctement ces ménages.

En milieu urbain, les performances globales sont nettement meilleures, avec une précision de 80,52% et un intervalle de confiance de 73,37% à 86,45%, traduisant une fiabilité accrue du modèle. La précision atteint 81,45% pour les ménages pauvres et 81,49% pour les ménages non pauvres, démontrant une constance dans la prédiction de ces catégories. Toutefois, le modèle rencontre des limites similaires pour les erreurs d'exclusion (53,11%) et d'inclusion (59,42%), ce qui reflète une certaine difficulté à distinguer ces ménages, même en milieu urbain.

En résumé, bien que le modèle présente des performances globales supérieures en milieu urbain, des erreurs persistantes dans les classifications d'exclusion et d'inclusion indiquent la nécessité d'affiner l'analyse des facteurs explicatifs pour améliorer la précision dans ces catégories spécifiques.

Par la suite, nous analyserons en détail les coefficients significatifs du modèle logistique multinomial afin d'identifier les variables explicatives qui influencent le plus les types d'erreurs de classification. L'interprétation des coefficients permettra de mieux comprendre l'impact de chaque variable sur la probabilité qu'un ménage soit correctement classé ou mal classé (inclusion ou exclusion) par rapport à la catégorie de référence. En examinant les coefficients, nous pourrons déterminer l'ampleur et la direction de l'influence de chaque variable. Cette analyse contribuera à mettre en évidence les facteurs les plus déterminants dans les erreurs de prédiction, offrant ainsi des pistes d'amélioration pour affiner les modèles de ciblage des ménages pauvres. Puisque la p valeur associée à chaque coefficient du tableau ci-dessous est nulle, nous n'allons pas la préciser dans le tableau. Pour le milieu rurale, on a le tableau suivant :

TABLEAU 3.7 – Facteurs explicatifs des erreurs du modèle en milieu rural

Variables		Non pauvre	Exclus	Inclus
Frigo	Non			
	Oui	14,53	13,71	-0,33
Mode d'évacuation des ordures ménagères	Ramassage			
	Dépotoir public	-1,31	-2,17	0,18
	Incinération	-2,90	-2,35	-0,38
	Enfouissement	13,69	-0,83	-12,03
	Dépôt sauvage	0,19	0,29	0,25
	Autres	-4,14	1,32	0,52
Mode d'évacuation des eaux usées	Puisard			
	Egout	8,74	7,78	1,21
	Trou creusé	5,40	5,52	-2,07
	Dans la nature	3,79	5,04	-2,16
	Autres	2,43	-8,94	-20,07
Type de logement	Appartement dans un immeuble			
	Maison à étage	0,71	1,06	-6,62
	Maison basse	2,99	1,56	-5,69
	Baraque	-2,57	-6,60	-5,04
Ventillateur	Non			
	Oui	6,42	5,34	1,55

Source : EHCVM 2022, calculs de l'auteur

Ce tableau révèle plusieurs relations importantes entre les variables explicatives et les types d'erreurs de classification. Pour la variable frigo, le fait de posséder un réfrigérateur plutôt que de ne pas en avoir augmente fortement la probabilité qu'un ménage soit classé comme non pauvre (14,53) ou exclus (13,71), tout en ayant un effet presque nul sur l'inclusion (-0,33).

Concernant le mode d'évacuation des ordures ménagères, utiliser un dépotoir public plutôt que le ramassage diminue légèrement la probabilité d'être classé comme non pauvre (-1,31) ou exclus (-2,17), mais augmente légèrement celle d'être classé dans la catégorie inclus (0,18). L'incinération réduit les probabilités dans toutes les catégories, avec des coefficients négatifs pour non pauvre (-2,90), exclus (-2,35) et inclus (-0,38). En revanche,

l'enfouissement augmente fortement la probabilité d'être classé comme non pauvre (13,69), mais réduit drastiquement celle d'être inclus (-12,03). Le dépôt sauvage n'a que de faibles effets sur les erreurs de classification, augmentant légèrement les chances d'être prédit comme non pauvre (0,19), exclus (0,29), ou inclus (0,25).

Pour le mode d'évacuation des eaux usées, l'utilisation d'un égout par rapport à un puisard augmente significativement les probabilités d'être classé comme non pauvre (8,74) ou exclus (7,78), mais a un effet moindre sur l'inclusion (1,21). Un trou creusé accroît également les probabilités de non pauvre (5,40) et exclus (5,52), mais diminue l'inclusion (-2,07). Évacuer les eaux usées dans la nature suit la même tendance, avec des effets positifs pour non pauvre (3,79) et exclus (5,04), et négatifs pour l'inclusion (-2,16). À l'inverse, les autres modes d'évacuation réduisent fortement les chances d'être exclus (-8,94) et inclus (-20,07).

Pour le type de logement, habiter dans une maison à étage augmente légèrement les probabilités d'être classé comme non pauvre (0,71) ou exclus (1,06), mais réduit l'inclusion (-6,62). De même, vivre dans une maison basse accroît les probabilités de non pauvre (2,99) et exclus (1,56), mais diminue les chances d'inclusion (-5,69). En revanche, habiter dans une baraque diminue fortement les probabilités dans toutes les catégories (non pauvre : -2,57, exclus : -6,60, inclus : -5,04).

Enfin, la possession d'un ventilateur augmente les probabilités d'être classé comme non pauvre (6,42) et exclus (5,34), avec un effet plus modéré sur l'inclusion (1,55). Ces résultats mettent en évidence l'impact des conditions de vie matérielles et des infrastructures sur la classification des ménages, avec des effets variables selon les modalités étudiées. Pour ce qui est du milieu urbain, la p valeur associée à chaque coefficients vaut également 0. Ainsi, on a le tableau suivant :

TABLEAU 3.8 – Facteurs explicatifs des erreurs de prédictions en milieu urbain

Variables		Non pauvre	Exclus	Inclus
Matériaux des murs	Ciment			
	Motte de terre/paille	-5307	-533	-6408
	Matériaux de récupération	-694	-696	-147
	Autres	3952	3954	4422
Type sanitaire	Chasse			
	Latrine	241	243	545
	Toilettes publiques	409	-770	-2565
	Aucune toilette	-2571	2656	3230
	Autres types	-5307	-533	-6408
Mode d'évacuation des ordures ménagères ménagères	Ramassage			
	Dépotoir public	1286	1286	-354
	Incinération	-842	-840	-1193
	Enfouissement	418	-11962	-4239
	Dépôt sauvage	-220	-220	-1548
	Autres	3220	3223	-50
Sources d'approvisionnement en eau	Robinet			
	Puit non protégé	-751	-750	-54
	Puits protégé	-62	-63	658
	Eau en surface	-166	-165	148
	Autres	344	344	2425
Taux d'emploi du ménage		7	7	-16

Source : EHCVM 2022, calculs de l'auteur

De ce tableau, sont mises en évidence des relations significatives entre les modalités des variables explicatives et les types d'erreurs de classification. Par exemple, concernant le mode d'évacuation des ordures ménagères, utiliser un dépotoir public plutôt que le ramassage augmente considérablement la probabilité qu'un ménage soit prédit comme non pauvre (coefficient de 1285) ou exclus (1286), mais diminue fortement la probabilité d'être classé dans la catégorie inclus (-353). À l'inverse, l'incinération réduit la probabilité d'être prédit dans toutes les catégories autres que pauvre, avec des coefficients négatifs pour non pauvre (-841), exclus (-840), et inclus (-1193).

Pour le type sanitaire, l'utilisation de latrines par rapport à la référence (chasse)

augmente légèrement la probabilité d'être prédit comme non pauvre (241), exclus (242) ou inclus (545). En revanche, ne disposer d'aucune toilette réduit la probabilité d'être non pauvre (-2570) tout en augmentant significativement celle d'être exclus (2656) ou inclus (3230). De même, la catégorie toilettes publiques diminue la probabilité d'inclusion (-2565), malgré un effet positif pour la prédiction en non pauvre (409).

En ce qui concerne les matériaux des murs, l'usage de matériaux de récupération diminue les chances d'être prédit comme non pauvre (-694) ou exclus (-696), mais a un effet moins marqué pour les inclus (-146). En revanche, la catégorie autres matériaux augmente fortement la probabilité d'être classé comme non pauvre (3952), exclus (3954) et surtout inclus (4422).

Pour la variable source d'eau, l'accès à un puits non protégé réduit les probabilités d'être classé comme non pauvre (-751) ou exclus (-750), mais n'affecte que faiblement l'inclusion (-55). En revanche, les sources d'approvisionnement en eau alternatives augmentent considérablement la probabilité d'être inclus (2424).

Enfin, le taux d'emploi du ménage a un effet positif sur la prédiction en non pauvre (7) et exclus (7), mais diminue fortement les chances d'être classé en inclus (-16). Ces résultats soulignent l'importance des conditions de vie matérielles et des services de base dans les erreurs de classification, avec des effets variables selon les modalités étudiées.

Chapitre 4

Principaux résultats et recommandations

...

Ce chapitre présente les principaux résultats de l'analyse descriptive, met en lumière certaines limites de l'étude et propose des recommandations visant à affiner et améliorer le ciblage des ménages pauvres au Sénégal.

4.1 Discusssion des résultats

L'objectif de ce travail est de déterminer les facteurs explicatifs des erreurs de prédiction du modèle de ciblage des ménages pauvres. Les analyses descriptives, les tests statistiques et le modèle multinomial ont permis de mettre en évidence plusieurs éléments clés concernant ces erreurs.

Les analyses descriptives ont révélé que les ménages réellement pauvres et ceux prédits comme pauvres présentent des profils similaires en ce qui concerne les conditions de vie, notamment le mode d'évacuation des ordures ménagères, les sources d'approvisionnement en eau, le type de sanitaire, le mode d'éclairage, ainsi que la possession d'équipements tels que des ventilateurs, des bonbonnes de gaz et des réfrigérateurs. De même, les ménages inclus à tort parmi les pauvres partagent des caractéristiques proches de celles des ménages effectivement pauvres pour ces mêmes variables. Les tests statistiques ont confirmé que les relations entre ces variables et les types d'erreurs sont statistiquement significatives, validant ainsi la première hypothèse de recherche.

Par ailleurs, les ménages classés par erreur comme non pauvres et ceux réellement non pauvres affichent des similitudes sur des variables comme le mode d'évacuation des ordures ménagères, les matériaux des toits et les matériaux des murs. Ces liaisons ont également été confirmées comme statistiquement significatives par les tests appliqués, ce

qui valide la seconde hypothèse de recherche.

L'analyse du modèle multinomial a montré que plusieurs facteurs influencent de manière significative les erreurs de prédiction dans les deux milieux de résidence. Les facteurs communs incluent la possession d'équipements (réfrigérateur, ventilateur, fer électrique), l'accès aux services sociaux de base (sources d'approvisionnement en eau, type sanitaire, mode d'évacuation des ordures ménagères), la taille du ménage, le taux de promiscuité et le taux d'emploi du ménage.

Cependant, des facteurs spécifiques à chaque milieu ont également été identifiés. En milieu urbain, la nature du sol, les matériaux de construction des toits, la région influencent significativement les erreurs de prédiction. En milieu rural, ce sont principalement les matériaux des murs, le mode d'évacuation des eaux usées et le type de logement qui contribuent aux erreurs de classification.

Les résultats du modèle multinomial indiquent aussi que certaines variables augmentent la probabilité de commettre des erreurs de prédiction. Parmi celles-ci figurent la possession d'équipements, la région, les matériaux des murs, la nature du sol, le mode d'évacuation des ordures ménagères, le statut d'occupation et le mode d'évacuation des eaux usées, la taille du ménage, le taux de promiscuité et le taux d'emploi du ménage. À l'inverse, des variables telles que le mode d'éclairage, le type sanitaire réduisent la probabilité de mal classer les ménages.

4.2 Limites du travail

- Ce travail a été réalisé en utilisant 20% des données de l'EHCVM II, c'est-à-dire celles qui ont servi à tester la valider du modèle de ciblage. Certes, il permet d'apprécier les facteurs déterminants des erreurs commises par le modèle mais, certaines catégories de la variable type d'erreus se retrouvent sous représentées. Ce qui peut avoir une influence sur la capacité à identifier tous les déterminants des erreurs du modèle de ciblage.
- Parmi les variables explicatives, certaines présentent un grand nombre de modalités. Certaines catégories constituées par ces modalités sont sous représentées compte tenu de la taille limitée des données. Toutefois, ces modalités n'ont pas été regroupé

en vue de conserver la logique des données utilisées pour construire le modèle de ciblage. Néanmoins, cela peut aussi influencer l'identification des facteurs explicatifs des erreurs du modèle de ciblage.

4.3 Perspectives et recommandations

Les analyses menées suggèrent plusieurs recommandations pour améliorer les performances du modèle de ciblage des ménages pauvres.

- Il est recommandé que, compte tenu des limites observées, la prise en compte des données complètes de l'EHCVM II permettra de confirmer les déterminants obtenus à l'issue de cette analyse.
- Les résultats ont permi d'identifier une première catégorie de variables qui ne sont liées aux types du modèle de ciblage, une seconde qui a une influence négative sur ces erreurs et une troisième qui influence positivement les erreurs. Les variables des deux prémières catégories ne constituent pas une limite pour la performance du modèle de ciblage. En revanche, celles de la troisième catégorie sont celles qui contribuent à augmenter la probabilité de mal cibler un ménage. Il convient donc de determiner un traitement approprié pour limiter leur influence sur le modèle de ciblage. Cela pourrait consister à faire un modèle stratifié suivant ces variables, ou à les supprimer du modèle si cela n'affecte pas sa performance ou à élaborer un système de pondération qui permettrait de pénaliser ces variables dans le modèle pour limiter leur influence.

Conclusion

En somme, ce travail a permis d'analyser les erreurs de prédiction de l'algorithme de ciblage des ménages pauvres, mis en place par la DMCI. À travers des analyses descriptives, des tests statistiques et l'élaboration d'un modèle logistique multinomial, les facteurs explicatifs des erreurs d'inclusion et d'exclusion ont été identifiés. Il ressort que des variables liées à la possession d'équipements (frigo, ventilateur, fer électrique, bonbonne de gaz), à l'accès aux services de base (sources d'approvisionnement en eau, type sanitaire, mode d'évacuation des ordures ménagères et des eaux usées) et à la situation géographique (région) influencent significativement les erreurs de classification. Bien que des facteurs communs aient été identifiés entre les milieux urbain et rural, des spécificités propres à chaque contexte ont également été mises en lumière. En milieu urbain, les erreurs de prédiction sont spécifiquement influencées par des variables telles que la nature du sol, les matériaux de construction des toits, la région et le mode d'éclairage. En revanche, en milieu rural, les erreurs de classification sont davantage expliquées par les matériaux des murs, le mode d'évacuation des eaux usées et le type de logement. Cette étude a permis de distinguer les facteurs qui ne sont pas liés aux types d'erreurs ou qui ont une influence négative, de ceux qui ont une influence positive sur la probabilité qu'un ménage soit mal classé par le modèle. Une question qui se dégage de ces analyses serait donc de savoir si une pénalisation des coefficients associées à cette dernière catégorie des variables permettrait d'améliorer les performances du modèle de ciblage.

Références bibliographiques

[1] Agüero, J. M., Carter, M. R., et Woolard, I. (2018). *Evaluation of targeting errors in social assistance programs in Peru*. Review of Development Economics, 22(3), 1000–1017.

[2] Alkire, S., et Foster, J. (2011). *Counting and multidimensional poverty measurement*. Journal of Public Economics, 95(7–8), 476–487.

[3] Bigman, D., et Fofack, H. (2000). *Geographical targeting for poverty alleviation*. World Bank Economic Review, 14(1), 129–145.

[4] Blumenstock, J., Cadamuro, G., et On, R. (2015). *Predicting poverty and wealth from mobile phone metadata*. Science, 350(6264), 1073–1076.

[5] Brown, C., et Ravallion, M. (2020). *Reassessing the targeting of social assistance using machine learning*. Journal of Economic Inequality, 18(1), 1–24.

[6] Carvalho, M., et Souza, P. (2019). *Random forest analysis in Brazilian social programs*. Brazilian Journal of Economics, 73(4), 345–368.

[7] Carvalho, M., Souza, P., et Ramos, M. (2019). *Multinomial logit analysis of social program errors : Evidence from Bolsa Família*. Journal of Economic Policy Reform, 22(2), 178–196.

[8] Coady, D., Grosh, M., et Hoddinott, J. (2004). *Targeting of Transfers in Developing Countries : Review of Lessons and Experience*. World Bank.

[9] Engstrom, R., Hersh, J., et Newhouse, D. (2017). *Poverty from space : Using high-resolution satellite imagery for estimating economic well-being*. World Bank Policy Research Working Paper No. 8284.

[10] Golan, J., Sicular, T., et Umapathi, N. (2020). *Sensitivity metrics in targeting accuracy*. Journal of Development Economics, 146, 102486.

[11] Grosh, M. E., et Baker, J. L. (1995). *Proxy Means Tests for Targeting Social Programs*. World Bank.

[12] Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., et Ermon, S. (2016). *Combining satellite imagery and machine learning to predict poverty*. Science, 353(6301), 790–794.

[13] Kidd, S., et Bailey, C. (2017). *The effectiveness of social protection targeting*. Development Pathways.

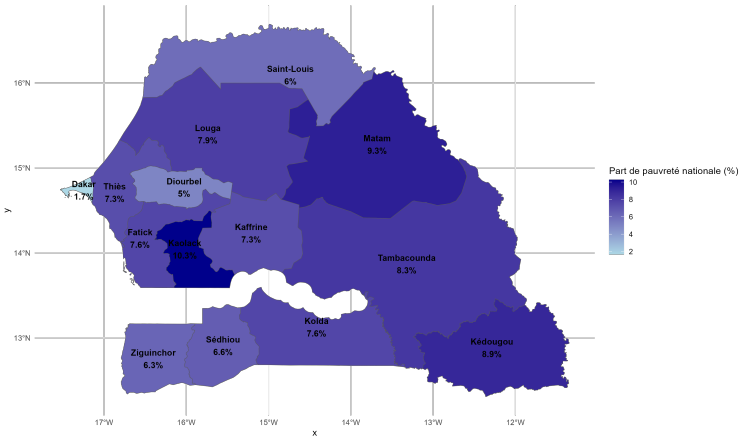
[14] Nie, P., Sousa-Poza, A., et Xue, J. (2021). *Targeting accuracy in poverty alleviation programs using machine learning*. Applied Economics, 53(7), 764–779.

[15] Rowntree, B. S. (1901). *Poverty : A Study of Town Life*. Macmillan.

[16] Sen, A. (1985). *Commodities and Capabilities*. North-Holland.

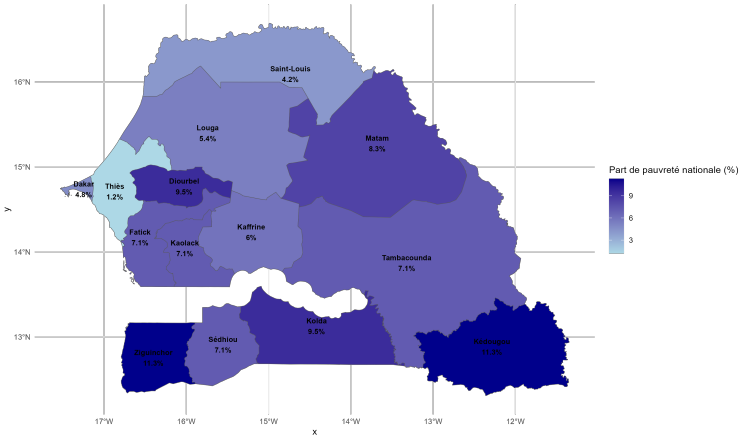
Annexes

Annexe 1 : Distribution de la pauvreté suivant les régions en milieu rural



Source : EHCVM 2022, HDX, calculs de l'auteur

Annexe 2 : Distribution de la pauvreté suivant les régions en milieu urbain



Source : EHCVM 2022, HDX, calculs de l'auteur

Annexe 3 : Autres facteurs explicatifs des erreurs de prédiction en milieu rural

		Non pauvre	Exclus	Inclus
fer électrique	Non			
	Oui	10,53	-2,39	11,33
Bonbonne de gaz	Non			
	Oui	4,10	2,08	0,33
fer à charbon	Non			
	Oui	0,71	1,03	0,92
Voiture	Non			
	Oui	15,39	4,01	2,25
sources d'approvisionnement en eaus	Robinet			
	Puit non protégé	2,34	2,05	-1,18
	Puits protégé	-0,29	-0,33	-0,25
	Eau en surface	10,78	-5,58	0,60
	Autres	-0,54	0,33	2,55
matériaux murs	Ciment			
	Motte de terre/paille	0,05	-0,67	-0,93
	Matériaux de récupération	-6,27	-13,21	-0,51
	Autres	2,75	2,20	0,72
p-value (p)	$0 < p < 0.00000001$			

Source : EHCVM 2022, calculs de l'auteur

Annexe 4 : Croisement entre la varaiable type d'erreur et quelques variables explicatives en milieu urbain

		Non pauvre	Exclus	Pauvre	Inclus
Mode évacuation des ordures	ramassage	12,83	12,70	18,10	27,27
	dépotoir_public	70,47	58,73	32,38	20,45
	incinération	6,68	14,29	20,00	25,00
	enfouissement	0,35	0,00	1,90	0,00
	dépôt_sauvage	8,79	12,70	27,62	27,27
	autres	0,88	1,59	0,00	0,00
Nature toit	Dalle en ciment(béton)	54,31	30,16	5,71	15,91
	Tuile(ardoise)	8,44	9,52	10,48	11,36
	Tôle(zinc)	34,97	58,73	75,24	70,45
	Chaume(paille)	1,41	1,59	8,57	2,27
	Bois(banco)	0,35	0,00	0,00	0,00
	Autres	0,53	0,00	0,00	0,00
Type sanitaire	chasse	65,73	38,10	29,52	31,82
	lattrine	33,22	60,32	60,00	63,64
	toilettes_publics	0,70	0,00	1,90	0,00
	aucune_toilette	0,35	1,59	2,86	4,55
	autres	0,00	0,00	5,71	0,00
Nature du mur	ciment	89,63	77,78	49,52	68,18
	banco_paille_tige_motte_terre	4,75	6,35	29,52	15,91
	nois_materiau_recuperation	0,53	1,59	1,90	9,09
	autres	5,10	14,29	19,05	6,82
Type de logement	appart_immeuble	27,94	17,46	1,90	6,82
	maison_etage	70,83	82,54	89,52	90,91
	maison_basse	0,35	0,00	0,00	2,27
	baraque	0,88	0,00	8,57	0,00
Mode d'éclairage	Senelec	94,20	82,54	62,86	61,36
	Générateur	2,46	4,76	1,90	4,55
	solaire	1,41	4,76	11,43	20,45
	lampe_rechargeable	1,23	4,76	19,05	13,64
	lampe artisanale	0,35	0,00	1,90	0,00
	Bois	0,35	3,17	2,86	0,00
	Autres	0,00	0,00	0,00	0,00

Source : EHCVM 2022, calculs de l'auteur

Annexe 5 : Croisement entre la varaiable type d'erreur et quelques variables explicatives en milieu rural

		Non pauvre	Pauvre	Exclus	Inclus
Nature toit	Dalle en ciment(béton)	27,31	3,19	21,57	8,08
	Tuile(ardoise)	10,50	9,56	7,84	6,06
	Tôle(zinc)	50,42	55,38	58,82	60,61
	Chaume(paille)	11,34	29,88	11,76	22,22
	Bois(banco)	0,42	1,20	0,00	3,03
	Autres	0,00	0,80	0,00	0,00
Type sanitaire	chasse	49,58	18,33	35,29	22,22
	lattrine	42,86	64,94	54,90	63,64
	Toilettes publics	1,68	1,59	3,92	0,00
	Aucune toilette	3,36	13,15	3,92	13,13
	Autres	2,52	1,99	1,96	1,01
Nature du mur	Ciment	70,17	45,42	62,75	48,48
	banco\motte de terre	19,75	44,62	23,53	34,34
	Nois\ materiau de récuperation	0,42	3,19	0,00	4,04
	Autres	9,66	6,77	13,73	13,13
Nature du sol	Carreaux marbres	27,73	2,39	13,73	7,07
	Ciment \béton	50,84	49,80	70,59	58,59
	Terre battue	20,59	43,43	15,69	32,32
	Autres	0,84	4,38	0,00	2,02
Mode d'éclairage	Senelec	61,34	21,51	49,02	28,28
	Générateur	5,04	3,19	3,92	1,01
	solaire	15,97	25,90	13,73	29,29
	lampe_rechargeable	15,97	48,61	29,41	40,40
	lampe artisanale	1,68	0,00	0,00	0,00
	Bois	0,00	0,80	3,92	1,01
	Autres	0,00	0,00	0,00	0,00
Mode d'évacuation d'eau	puisard	10,92	1,99	3,92	5,05
	egout	7,56	1,59	1,96	7,07
	trou_creusé	15,13	13,94	15,69	10,10
	Dans la nature	63,45	78,09	78,43	77,78
	autres	2,94	4,38	0,00	0,00

Source : EHCVM 2022, calculs de l'auteur

Annexe 6 : Autres facteurs explicatifs en milieu urbain

		Non pauvre	Exclus	Inclus
Nature du sol	Carreaux\marbres			
	Ciment\béton	-628,49	-625,85	534,07
	Terre battue	-1662,23	-1657,38	236,49
	Autres	-2153,44	-2611,64	-1377,49
Matériaux des toits				
	Tuile(ardoise)	-1301,18	-1301,26	-2243,52
	Tôle(zinc)	-948,03	-947,57	-1393,66
	Chaume(paille)	-3400,72	-3397,74	-1552,00
	Bois(banco)	8695,22	-3118,35	-3015,40
	Autres	-452,20	-821,82	551,35
Mode d'éclairage	Senelec			
	Générateur	-69,15	-69,45	-248,66
	Lampe solaire	999,81	219,25	924,11
	Lampe_rechargeable	-1264,19	-1260,91	-1515,44
	Lampe artisanale	-2761,77	-1402,89	-5632,15
	Bois	-4410,09	-4405,41	-5932,74
Région	Dakar			
	Ziguinchor	-6988,47	-6987,96	3182,09
	Diourbel	-6845,13	-6845,40	2483,42
	Saint-Louis	-3786,70	-3787,21	5796,90
	Tambacounda	-5085,98	-5086,80	4504,14
	Kaolack	-5701,96	-5701,56	2468,49
	Thiès	-3398,30	-3398,28	2737,20
	Louga	-1800,91	-1798,72	7575,21
	Fatick	-9022,55	-9020,62	-177,17
	Kolda	-5523,79	-5522,76	5220,12
	Matam	-4433,07	-4433,15	4683,00
	Kaffrine	-1157,85	-1156,03	6501,46
	Kédougou	-6147,77	-6145,79	3710,24
	Sédhiou	-5648,25	-5645,21	5125,68
P-value (p)	$0 < p < 0.00001$			

Source : EHCVM 2022, calculs de l'auteur

Table des matières

Décharge i

Remerciements ii

Avant-propos iii

Sommaire iv

Sigles et abréviations v

Liste des figures vi

Liste des tableaux vii

Résumé 1

Introduction 2

1 Présentation de la structure d'accueil : ANSD 5

1.1 Historique et missions 5

1.1.1 Historique 5

1.1.2 Missions 5

1.2 Les services centraux 7

1.2.1 Direction des Statistiques Économiques et de la Comptabilité Nationale (DSECN) 7

1.2.2 Direction des Statistiques Démographiques et Sociales (DSDS) 8

1.2.3 Direction des Systèmes d'Information et de la Diffusion (DSID) . . . 8

1.2.4 Direction de l'Administration Générale et des Ressources Humaines (DAGRH) 8

1.2.5 Direction de l'École Nationale de la Statistique et de l'Analyse Économique Pierre Ndiaye (ENSAE) 9

1.2.6 Agence Comptable (AC) . . . 9
1.2.7 La Direction de la Méthodologie, de la Coordination statistique et de l'Innovation (DMCI) . . . 9
1.2.8 Direction à l'Action Régionale (DAR) . . . 11
1.3 Missions pendant le stage . . . 12

2 Cadre conceptuel et source de données 14
2.1 Revue de littérature . . . 14
2.1.1 Les méthodes traditionnelles pour la prédiction de la pauvreté . . . 14
2.1.2 Introduction du machine learning dans le ciblage des ménages pauvres 16
2.2 Méthodologie . . . 20
2.2.1 Source de données . . . 20
2.2.2 Présentation des variables . . . 21
2.2.3 Méthode d'analyse . . . 23

3 Présentation et interprétation des résultats de l'analyse bivariée, des tests statistiques et du modèle 26
3.1 Analyse descriptive . . . 26
3.1.1 Analyse croisée des biens des ménages et des indicateurs de pauvreté : Réel vs Prédit . . . 27
3.1.2 Analyse de la pauvreté réelle et prédite en fonction du mode d'évacuation des ordures ménagères . . . 28
3.1.3 Analyse de pauvreté réelle et prédite en fonction des sources d'approvisionnement en eau . . . 30
3.1.4 Analyse de pauvreté réelle et prédite en fonction des sources d'approvisionnement en infrastructures sanitaires . . . 31
3.1.5 Analyse de pauvreté réelle et prédite en fonction des matériaux des toits . . . 33
3.1.6 Analyse de pauvreté réelle et prédite en fonction des types de logement 34
3.1.7 Analyse de pauvreté réelle et prédite en fonction du mode d'éclairage 35
3.1.8 Analyse de pauvreté réelle et prédite en fonction du mode d'évacuation des eaux usées . . . 36
3.2 Analyse des erreurs . . . 38

3.2.1 Milieu rural 38
3.2.2 Milieu urbain 43
3.3 Relation entre chaque variable prédictive et la variable type d'erreur 45
3.3.1 Milieu urbain 45
3.3.2 Milieu rural 47
3.4 Modèle logistique multinomial 49

4 Principaux résultats et recommandations **55**
4.1 Discusssion des résultats 55
4.2 Limites du travail 56
4.3 Perspectives et recommandations 57

Conclusion **58**

Références bibliographiques **59**

Annexes **I**

Table des matières **V**